الجمهورية العربية السورية
وزارة التعليم العالي
الجامعة الافتراضية السورية

نظام تصنيف اورام الدماغ
Brain Tumor Classification System

تقديم الطلاب:

عقبة السعدي Okba_132316

هشام السعدي Hesham_174149

بإشراف د. محمد حجّوز

الفصل الدراسي: F24

الصف: C71

8/2/2026

الفهرس

المقدمة (Introduction) 2
{ الباب الأول (تعريف المشروع) } 3
الهدف من المشروع (Project Objectives) 4
الشروط والمتطلبات (Requirements Analysis) 5
{ الباب الثاني (الدراسة المرجعية) } 6
خلفية طبية وتقنية (Technical Background & Medical) 7
الخوارزميات المستخدمة (Algorithms) 7
{ الباب الثالث (الدراسة التحليلية) } 10
التخطيط 11
تحليل البيانات (Data Analysis) 14
تحليل النماذج (Model Analysis) 17
تحليل المتطلبات: 25
{ الباب الرابع (التصميم) } 28
بنية النظام (System Architecture) 29
تصميم النموذج النهائي (Final Model Design) 31
{ الباب الخامس (التحقيق البرمجي) } 35
بيئة العمل (Development Environment) 36
المعالجة المسبقة للبيانات (Data Preprocessing) 36
استراتيجية تدريب النموذج (Training Strategy) 37
{ الباب السادس (التنفيذ والاختبارات) } 38
نتائج النموذج النهائي (Final Model Results) 39
تحليل مصفوفة الارتباك (Confusion Matrix Analysis) 40
مقارنة النماذج (Models Comparison) 41
اختبارات التطبيق (Application Testing) 42
{ الباب السابع (الخاتمة والآفاق المستقبلية) } 43
ملخص الإنجازات 44
تحسين أداء النموذج (Model Performance Enhancement) 44
آفاق مستقبلية (Future Research) 44
الخاتمة 45
المراجع (References) 46

المقدمة (Introduction)

تُعد أورام الدماغ تحدياً صحياً عالمياً جسيماً، حيث تمثل نسبة كبيرة من الوفيات المرتبطة بالسرطان وتؤثر بشكل عميق على جودة حياة المرضى، ويتطلب التشخيص الدقيق والسريع لهذه الأورام تدخلاً طبياً فورياً، فكل تأخير قد يؤدي إلى تدهور الحالة الصحية للمريض. تاريخياً، اعتمد التشخيص بشكل أساسي على الفحص السريري، ثم تطور ليشمل تقنيات التصوير الطبي المتقدمة مثل التصوير بالرنين المغناطيسي (Magnetic Resonance Imaging – MRI)، والذي يُعد المعيار الذهبي لتصوير الأنسجة الرخوة في الدماغ.

على الرغم من التطور الهائل في تقنيات التصوير، فإن تفسير صور الرنين المغناطيسي يظل عملية معقدة تتطلب خبرة واسعة من أطباء الأشعة، هذه العملية ليست فقط مستهلكة للوقت، بل إنها أيضاً عرضة للاختلافات بين الأطباء، وقد تتأثر بعوامل مثل الإرهاق البشري أو نقص الوقت الكافي للتشخيص. هذه التحديات دفعت بالبحث العلمي نحو استكشاف حلول مبتكرة يمكنها دعم الأطباء وتحسين دقة وكفاءة التشخيص.

في العقود الأخيرة، شهد مجال الذكاء الاصطناعي (Artificial Intelligence – AI)، وتحديداً فرعه التعلم العميق (Deep Learning – DL)، طفرة نوعية في تطبيقاته المختلفة، خاصة في مجال الرؤية الحاسوبية (Computer Vision). لقد أظهرت الشبكات العصبية التلافيفية (Convolutional Neural Networks – CNNs) قدرات غير مسبوقة في تحليل الصور، والتعرف على الأنماط المعقدة، وتصنيف الكائنات بدقة عالية. هذه القدرات جعلت التعلم العميق أداة واعدة بشكل خاص في تحليل الصور الطبية، حيث يمكنه استخلاص ميزات دقيقة من صور الرنين المغناطيسي قد لا تكون واضحة للعين البشرية، مما يفتح آفاقاً جديدة لتشخيص الأمراض بدقة وسرعة أكبر.

يهدف هذا المشروع إلى تسخير قوة التعلم العميق لتطوير نظام آلي متكامل وفعال لتصنيف أورام الدماغ من صور الرنين المغناطيسي. نسعى من خلال هذا العمل إلى بناء نموذج قادر على التمييز بين أربع فئات رئيسية: الورم الدبقي (Glioma)، الورم السحائي (Meningioma)، ورم الغدة النخامية (Pituitary Tumor)، بالإضافة إلى الحالات السليمة (No Tumor). يمثل هذا النظام خطوة مهمة نحو تقديم أداة مساعدة للأطباء، تساهم في تقليل الأخطاء التشخيصية، تسريع عملية اتخاذ القرار العلاجي، وبالتالي تحسين نتائج الرعاية الصحية للمرضى. سيتم التركيز على تحقيق دقة وموثوقية عاليتين في التصنيف، مع تقديم تحليل معمق للجوانب التقنية والطبية للمشروع، بما يتناسب مع مستوى الأبحاث المتقدمة في هذا المجال.

الباب الأول (تعريف المشروع)

الهدف من المشروع (Project Objectives)

يتمحور الهدف الجوهري لهذا البحث حول بناء وتطوير نموذج حاسوبي متقدم يعتمد على الشبكات العصبية التلافيفية (CNN) لتصنيف أورام الدماغ، ويمكن تلخيص الأهداف التفصيلية فيما يلي:

1- **التصنيف المتعدد الفئات (Multi-class Classification)**: التمييز بدقة بين ثلاثة أنواع من الأورام (Glioma, Meningioma, Pituitary) بالإضافة إلى الحالات السليمة (No Tumor).

2- **تحسين الدقة التشخيصية**: الوصول إلى معدلات دقة (Accuracy) تجاوزت 94%، مع تقليل معدلات الخطأ في التصنيف (False Negatives) لضمان عدم إغفال أي حالة مرضية.

3- **المقارنة المنهجية**: إجراء دراسة مقارنة بين عدة بنى هندسية للشبكات العصبية، بما في ذلك النماذج المخصصة (Custom CNN) والنماذج سابقة التدريب (Pre-trained Models) مثل ResNet50V2 وMobileNetV2.

4- **تطوير نظام معالجة متكامل**: بناء سلسلة بيانات (Data Pipeline) تشمل التنظيف، المعالجة المسبقة، وزيادة البيانات (Data Augmentation) لضمان متانة النموذج وقدرته على التعميم والتوسع مستقبلياً.

أهمية المشروع والمشكلة التي يحلها

تتسم أورام الدماغ بتعقيد تشخيصها وتأثيرها المدمر على الوظائف العصبية، فيكون التشخيص المبكر والدقيق لأورام الدماغ أمر بالغ الأهمية لتحسين فرص العلاج ونتائج المرضى، يعتمد تشخيص أورام الدماغ بشكل كبير على تفسير أطباء الأشعة لصور الرنين المغناطيسي (MRI)، وهي عملية تتطلب خبرة عالية، وتستغرق وقتاً طويلاً، يضاف إلى ذلك، التزايد المستمر في حجم البيانات الطبية، مما يضع عبئاً كبيراً على الكوادر الطبية.

هنا تبرز أهمية هذا المشروع، حيث يهدف إلى تقديم حل مبتكر وفعال لهذه المشكلة من خلال تطوير نظام آلي لتصنيف أورام الدماغ باستخدام تقنيات التعلم العميق. يحل هذا النظام مشكلة الاعتماد الكلي على التفسير البشري، مقدماً "رأياً ثانياً" موضوعياً وسريعاً يساعد الأطباء في اتخاذ قرارات تشخيصية أكثر دقة وفي وقت أقل. من خلال تسخير قوة الشبكات العصبية التلافيفية (CNNs) في تحليل الأنماط المعقدة داخل صور الرنين المغناطيسي، يمكن للنظام تحديد وجود الورم ونوعه بدقة عالية، مما يساهم في:

1- **تحسين دقة التشخيص**: تقليل الأخطاء التشخيصية وزيادة الثقة في النتائج.

2- **تسريع عملية التشخيص**: توفير الوقت الثمين للأطباء والمرضى، مما يتيح بدء العلاج في مراحله المبكرة.

3- **تخفيف العبء على الكوادر الطبية**: أتمتة جزء من عملية التحليل، مما يسمح للأطباء بالتركيز على الحالات الأكثر تعقيداً.

4- **توفير أداة مساعدة للتدريب**: يمكن استخدام النظام كأداة تعليمية للأطباء المتدربين لفهم خصائص الأورام المختلفة.

بالتالي، فإن هذا المشروع لا يمثل مجرد تطبيق تقني، بل هو مساهمة حقيقية في تحسين جودة الرعاية الصحية، وتقليل المعاناة البشرية، وتعزيز كفاءة المنظومة الطبية في مواجهة أحد أخطر الأمراض.

الشروط والمتطلبات (Requirements Analysis)

1- المتطلبات الوظيفية (Functional Requirements)

- **تصنيف الحالة الطبية**: يجب أن يكون النظام قادراً على تصنيف الحالة الموجودة في الصورة إذا كانت من الحالات الأربعة التي تم تدريب النموذج عليها.
- **دعم الصيغ المختلفة من الصور**: يجب أن يوفر النظام القدرة على استقبال صور MRI بصيغ مختلفة، والقيام بعمليات المعالجة الآلية دون تدخل بشري.
- **معالجة مسبقة للصور**: يقوم النظام بمعالجة الصور المدخلة (مثل إزالة الصور المكررة، والملفات التالفة، وتوحيد الأبعاد) قبل تحليلها.
- **عرض النتائج**: إخراج التنبؤ النهائي مع نسبة الثقة (Confidence Score).

2- المتطلبات غير الوظيفية (Non-Functional Requirements)

- **الدقة والموثوقية**: يجب أن يكون النموذج موثوقاً طبياً إلى حد كبير، ليقبل المشرف الطبي بالاعتماد على نتائج النموذج.
- **الكفاءة الزمنية**: القدرة على إعطاء النتيجة في غضون ثوانٍ قليلة لتسريع العملية التشخيصية في وقت حساس للمريض.
- **القابلية للتوسع**: إمكانية إضافة فئات جديدة من الأورام أو تحسين النموذج ببيانات إضافية مستقبلاً.

3- المتطلبات التقنية (Environmental Requirements)

يتطلب المشروع بيئة برمجية تعتمد على لغة Python، واستخدام مكتبات متخصصة مثل TensorFlow وKeras لبناء النماذج، وOpenCV لمعالجة الصور، بالإضافة إلى موارد حسابية قوية (GPU) للتعامل مع العمليات الرياضية المعقدة للشبكات العصبية.

- **لغات وأطر البرمجة**: نعتمد على لغة البرمجة Python كركيزة أساسية لتطوير النظام، ونستخدم مكاتب متخصصة للتعلم العميق مثل TensorFlow وKeras لبناء وتدريب نماذجنا، وOpenCV لمعالجة الصور.
- **نماذج التعلم العميق**: نقوم بالتدريب على موارد حاسوبية قوية GPU وTPU من Google Colab، ونوظف عدة نماذج لتتعلم العميق، بما في ذلك MobileNetV2 وResNet50V2 وEfficientNetB0، كما نبني شبكة عصبونية تلافيفية Custom CNN، ونختم بمقارنة جميع النماذج لضمان أفضل أداء لتحليل الصور الطبية.
- **بيئة النشر**: تعذر نشر الموقع الرئيسي (Python/Flask) على استضافة بسبب حجم النموذج الكبير، وعدم وجود استضافة مجانية تدعم هذا الحجم، سنلتزم بتصميم التطبيق المطلوب، وسنحاول تقديم صور مرفقة للواجهات وطريقة عمل التطبيق.

الباب الثاني (الدراسة المرجعية)

خلفية طبية وتقنية (Technical Background & Medical)

أنواع أورام الدماغ المستهدفة:

تختلف الأورام الدماغية في منشئها وسلوكها الحيوي، وهو ما ينعكس على مظهرها في صور الرنين المغناطيسي:

- **الورم الدبقي (Glioma)**: ينشأ من الخلايا الدبقية في الدماغ أو الحبل الشوكي، ويتميز بحدود غير واضحة غالباً ويتداخل مع الأنسجة السليمة.
- **الورم السحائي (Meningioma)**: ينشأ من الأغشية التي تغطي الدماغ، وعادة ما يكون حميداً وبطيء النمو مع حدود واضحة.
- **ورم الغدة النخامية (Pituitary Tumor)**: يظهر في قاعدة الدماغ ويؤثر على الوظائف الهرمونية، وله مظهر مميز في الصور المقطعية.

الخوارزميات المستخدمة (Algorithms)

قمنا بالتركيز على بحث وتطبيق مجموعة متنوعة من الشبكات العصبية التلافيفية (CNNs)، بدءاً من النموذج الذي قمنا ببنائه (Custom CNN) وصولاً إلى النماذج المعقدة مسبقة التدريب (Pre-trained Models) التي أثبتت كفاءتها في مهام الرؤية الحاسوبية، يهدف هذا التنوع إلى تقييم الأداء النسبي لكل بنية وتحديد الأنسب لمشكلتنا.

الشبكات العصبية التلافيفية المخصصة (Custom CNN)

تُعد الشبكات العصبية التلافيفية (CNNs) حجر الزاوية في معظم تطبيقات الرؤية الحاسوبية الحديثة، وقد أحدثت ثورة في معالجة الصور والفيديو. تعتمد الـ CNNs على مبدأ استخلاص الميزات الهرمي (Hierarchical Feature Extraction) من خلال سلسلة من الطبقات التلافيفية (Convolutional Layers)، طبقات التجميع (Pooling Layers)، وطبقات التفعيل (Activation Functions).

رياضياً، تقوم النواة K بالانزلاق فوق الصورة I لحساب مجموع حاصل ضرب قيم البكسلات في النواة. في سياق الشبكات العصبية، تتعلم هذه النوى (الفلاتر) بشكل تلقائي الميزات الهامة مثل الحواف، الزوايا، والتدرجات اللونية.

تتكون بنية الـ Custom CNN التي قمنا ببنائها من طبقات تلافيفية متعددة تليها طبقات تجميع لتقليل الأبعاد المكانية (Spatial Dimensions) وتقليل عدد المعاملات، مما يساعد في جعل النموذج أكثر قوة ضد التشوهات الطفيفة في المدخلات (Translation Invariance)، استخدمنا دالة التفعيل ReLU (Rectified Linear Unit) بعد كل طبقة تلافيفية لإدخال اللاخطية (Non-linearity) في النموذج، مما يسمح له بتعلم علاقات أكثر تعقيداً في البيانات.

ResNet50V2

تُعد شبكات ResNet (Residual Networks) إحدى أهم الابتكارات في مجال التعلم العميق، وقد ساهمت بشكل كبير في حل مشكلة التلاشي المتدرج (Vanishing Gradient) التي كانت تعيق تدريب الشبكات العميقة، قدمت ResNet مفهوم (Skip Connections) أو بقايا الكتل (Residual Blocks)، والتي تسمح للمعلومات بالقفز فوق طبقة أو أكثر والوصول مباشرة إلى الطبقات اللاحقة. هذا يسمح للشبكة بتعلم "البقايا" (Residuals) بدلاً من تعلم التحويل الكامل، مما يسهل تدريب الشبكات ذات العمق الكبير جداً.

تعتمد بنية ResNet50V2 على 50 طبقة، وتتميز عن سابقتها ResNet50 بتقديم تحسينات في ترتيب طبقات Batch Normalization وActivation داخل الكتلة المتبقية، في ResNetV2، يتم تطبيق Batch Normalization ثم دالة التفعيل (ReLU) قبل عملية التلافيف (Pre-activation)، مما يؤدي إلى تدفق معلومات أكثر سلاسة واستقراراً للمتدرجات عبر الشبكة. الكتلة المتبقية الأساسية في ResNet50V2 يمكن تمثيلها رياضياً كالتالي:

$$y = f(x) + x$$

حيث x هو مدخل الكتلة، وF(x) يمثل تابع التحويل التلافيفي للطبقات داخل الكتلة، هذه البنية تسمح للشبكة بتعلم (Identity Functions) بسهولة، مما يضمن أن إضافة المزيد من الطبقات لن يؤدي إلى تدهور الأداء. لقد تم استخدام ResNet50V2 كنموذج أساسي (Backbone) في هذا المشروع، حيث تم الاستفادة من أوزانه المدربة مسبقاً على مجموعة بيانات ImageNet الضخمة، ثم تم تعديل الطبقات النهائية (Head Classifier) لتناسب هدف تصنيف أورام الدماغ.

MobileNetV2

صُممت شبكات MobileNetV2 خصيصاً لتطبيقات الرؤية الحاسوبية على الأجهزة ذات الموارد المحدودة مثل الهواتف الذكية والأجهزة المدمجة، الهدف الرئيسي من MobileNetV2 هو تحقيق دقة عالية مع الحفاظ على عدد قليل من المعاملات (Parameters) والعمليات الحسابية (FLOPs)، مما يجعلها سريعة وفعالة.

الابتكار الأساسي في MobileNetV2 يكمن في استخدام "التلافيف القابلة للفصل" (Depthwise Separable Convolutions) و"بقايا الكتل المقلوبة" (Inverted Residual Blocks) و(Linear Bottlenecks).

Depthwise Separable Convolutions تقسم عملية التلافيف القياسية إلى خطوتين:

1- **Depthwise Convolution**: تطبيق فلتر واحد لكل قناة إدخال بشكل منفصل.

2- **Pointwise Convolution** (**1x1**): دمج مخرجات Depthwise Convolution عبر القنوات باستخدام تلافيف (1x1)

هذا التقسيم يقلل بشكل كبير من عدد العمليات الحسابية مقارنة بالتلافيف التقليدية.

أما Inverted Residual Blocks، فهي تختلف عن كتل ResNet التقليدية، فبدلاً من تقليل الأبعاد ثم زيادتها، تقوم MobileNetV2 بتوسيع الأبعاد في البداية (باستخدام تلافيف 1x1)، ثم تطبيق Depthwise Convolution، ثم تقليل الأبعاد مرة أخرى (باستخدام تلافيف 1x1). ويتم استخدام Linear Bottlenecks في طبقات التضييق (Bottleneck Layers) النهائية، حيث يتم استبدال دالة ReLU بدالة تفعيل خطية لتجنب فقدان المعلومات في الأبعاد المنخفضة.

هذه البنية تجعل MobileNetV2 خياراً ممتازاً عندما تكون سرعة الاستدلال (Inference Speed) وكفاءة الموارد ذات أهمية قصوى.

EfficientNetB0

تُعد EfficientNet عائلة من النماذج التي تم تطويرها باستخدام تقنية (Compound Scaling)، والتي تسمح بتحسين أداء الشبكة بشكل منهجي من خلال تحجيم ثلاثة أبعاد رئيسية للشبكة بشكل متوازن: العمق (Depth)، العرض (Width)، ودقة الصورة المدخلة (Resolution)، فبدلاً من تحجيم هذه الأبعاد بشكل مستقل، تستخدم EfficientNet معامل تحجيم مركب phi لضبطها جميعاً في نفس الوقت.

بنية EfficientNetB0 هي النموذج الأساسي في هذه العائلة، وتعتمد على كتل MBConv (Mobile Inverted Bottleneck Convolution) المستوحاة من MobileNetV2، ولكن مع تحسينات إضافية مثل استخدام Squeeze-and-Excitation (SE) blocks لتعزيز قدرة النموذج على التركيز على الميزات الأكثر أهمية. على الرغم من أن EfficientNetB0 يُعرف بكفاءته العالية ودقته الجيدة مقارنة بحجمه، إلا أنه في سياق هذا المشروع، واجه صعوبة في التقارب (Convergence) وتحقيق أداء مماثل للنماذج الأخرى، ربما بسبب خصائص معينة لمجموعة بيانات صور الرنين المغناطيسي أو الحاجة إلى ضبط دقيق جداً للمعاملات الفائقة (Hyperparameters) الخاصة به.

الباب الثالث (الدراسة التحليلية)

التخطيط

منهجية التطوير (Development Methodology)

اعتمدنا في هذا المشروع على منهجية CRISP-DM (Cross-Industry Standard Process for Data Mining)، وهي منهجية دورية تضمن الترابط بين الأهداف الطبية والحلول التقنية، تشمل هذه المنهجية ست مراحل تبدأ بفهم متطلبات المجال الطبي، مروراً بفهم البيانات وتحضيرها، وصولاً إلى النمذجة والتقييم ثم النشر.

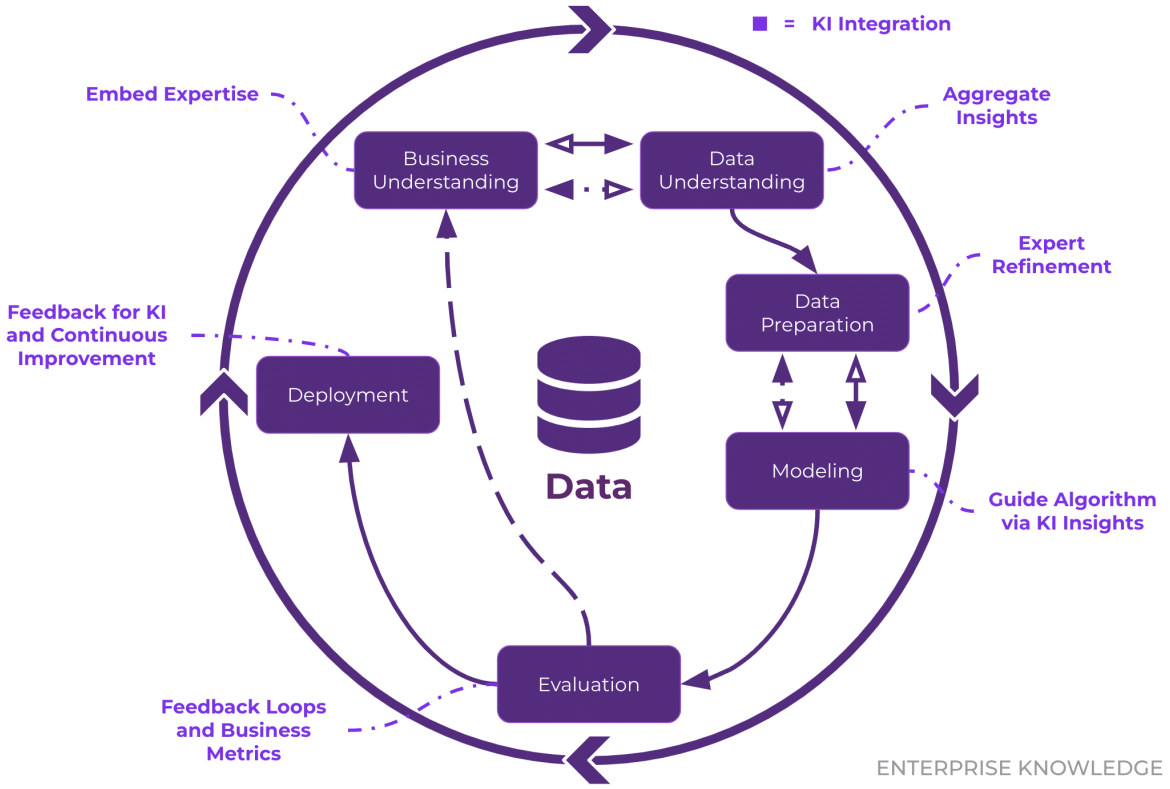

دراسة الجدوى (Feasibility Study)

تم إجراء دراسة جدوى شاملة للمشروع من ثلاثة جوانب:

- **الجدوى التقنية (Technical Feasibility)**:

تأكدنا من توفر الخوارزميات اللازمة (Deep Learning Frameworks) والقدرة الحسابية (GPUs) لمعالجة آلاف الصور الطبية باستخدام الأدوات المتاحة مثل Google Colab.
كما تأكدنا من وصولنا إلى المكتبات اللازمة مثل TensorFlow، Keras، Flask لتطبيق المشروع، ولغة Python.

- **الجدوى التشغيلية (Operational Feasibility)**:

النظام مصمم ليدمج بسهولة في سير عمل أطباء الأشعة، حيث يوفر "رأياً ثانياً" (Second Opinion) يعزز من دقة التشخيص ويسرع من العملية.
يتم ذلك من خلال واجهة بديهية تضمن سهولة الاستخدام للطاقم غير المدرب على التعامل مع النظام.

- **الجدوى الاقتصادية (Economic Feasibility)**:

من حيث التكلفة فبناء النظام كان شبه مجاني فكل الأدوات والمكتبات المستخدمة كانت متاحة تماماً بشكل مجاني.
أما من حيث الفائدة فنعتقد أن النظام سيساهم في تقليل التكاليف الناتجة عن التشخيص الخاطئ أو التأخر في بدء العلاج، كما يوفر وقت الكوادر الطبية المتخصصة.

التخطيط لإدارة المشروع (Project Management Planning)

موارد المشروع (Project Resources)

- **الموارد البشرية:** فريق المشروع المكون من الطالبين Hesham_174149, okba_132316.
- **الموارد البرمجية:**
  - لغات البرمجة: Python, html, CSS, JS.
  - أطر التعلم العميق: TensorFlow, Keras.
  - مكتبة معالجة الصور OpenCV.
  - واجهة المستخدم: Flask (لإنشاء تطبيق الويب).
  - بيئة التطوير: Google Colab, VSCode (للتدريب على النماذج).
- **الموارد المادية:** أجهزة حاسوب شخصية وبيئات حوسبة سحابية (Google Colab GPU) لتدريب النماذج التي تتطلب موارد حاسوبية مكثفة.

إدارة المخاطر (Risk Management)

تم تحديد عدة مخاطر محتملة خلال مراحل المشروع وتم التعامل معها:

- **نقص البيانات أو جودتها:** تم التخفيف من هذا الخطر من خلال البحث عن Dataset مناسبة وذات جودة عالية، بالإضافة إلى تطبيق تقنيات المعالجة المسبقة للصور لضمان نظافة البيانات.
- **صعوبة تدريب النموذج:** تم التعامل مع هذا الخطر من خلال تجربة نماذج وخوارزميات متعددة (Custom CNN، MobileNetV2، ResNet50V2، EfficientNetB0) واختيار الأنسب منها.
- **قيود الموارد الحاسوبية:** تم التخفيف من هذا الخطر من خلال تحسين النماذج لتقليل متطلبات الموارد، واستخدام بيئات حوسبة سحابية توفر موارد GPU.
- **دقة النموذج:** تم معالجة هذا الخطر من خلال التقييم المستمر لأداء النموذج باستخدام مقاييس مثل F1-score وAccuracy، وتحسين النموذج بناءً على هذه التقييمات.

تقدير الزمن والمسار الحرج (Time Estimation and Critical Path)

تم تقسيم المشروع إلى مراحل رئيسية، مع تقدير زمني لكل مرحلة:

1- مرحلة البحث والدراسة الأولية

2- مرحلة جمع البيانات والمعالجة المسبقة: تضمنت تنظيف البيانات وتجهيزها للتدريب.

3- مرحلة تطوير النماذج الأولية: شملت تجربة غدد من الخوارزميات المختلفة لتدريب models.

4- مرحلة تطوير النموذج النهائي: تم التركيز على ResNet50V2 Model لتحقيق أفضل أداء.

5- مرحلة بناء تطبيق الويب: تم تطويره باستخدام لغات الويب المعتادة.

6- مرحلة إعداد التقرير النهائي: تجميع كل المخرجات في التقرير الحالي.

كان المسار الحرج للمشروع يتمثل في تطوير نموذج التعلم العميق الذي يحقق الدقة المطلوبة (بشكل مجاني وخلال مدة التسليم)، حيث تطلب ذلك عدة تكرارات وتعديلات.

التنفيذ والمراقبة (Implementation and Monitoring)

تم تنفيذ المشروع بشكل تكراري، حيث تم تطوير كل مكون (معالجة البيانات، بناء النموذج، واجهة المستخدم) على مراحل، تمت مراقبة أداء النموذج بشكل مستمر خلال عملية التدريب باستخدام مقاييس التقييم، وتم إجراء التعديلات اللازمة لتحسين الأداء، كما تم اختبار تطبيق الويب لضمان عمله بشكل صحيح على Local computer.

تحليل البيانات (Data Analysis)

يعتبر تحليل البيانات المرحلة الأساسية التي تسبق أي عملية نمذجة في مشاريع تعلم الآلة، فقمنا بفحص معمق لمجموعة البيانات المستخدمة، بهدف فهم خصائصها، توزيعها، وتحدياتها المحتملة. هذا الفهم العميق مكّننا من اتخاذ قرارات مستنيرة فيما يتعلق بالمعالجة المسبقة، واختيار بنية النموذج المناسبة.

1– تحميل مجموعة البيانات والتنظيف الأولي (Dataset Loading and Initial Cleaning)

الخطوة الأولى تتمثل في تحميل البيانات وتنظيمها في هيكل برمجي يسهل التعامل معه، تم تحميل مجموعة البيانات من منصة Kaggle، وهي منظمة في مجلدات منفصلة لكل فئة من الفئات الأربع.

بعد تحديد المسارات، قمنا بإنشاء DataFrame باستخدام مكتبة Pandas لتخزين مسار كل صورة مع التسمية (Label) المقابلة لها. هذا الأسلوب يوفر مرونة كبيرة في معالجة البيانات وتصفيتها لاحقاً.

```
dataset_path = '/content/Training'

def check_structure(base_path):
    print(f"Checking structure for: {base_path}")
    classes = os.listdir(base_path)
    print(f"Classes found: {classes}")

    stats = {}
    for class_name in classes:
        class_path = os.path.join(base_path, class_name)
        if os.path.isdir(class_path):
            num_images = len(os.listdir(class_path))
            stats[class_name] = num_images
            print(f" - {class_name}: {num_images} images")
    return stats

training_stats = check_structure(dataset_path)
```

```
Checking structure for: /content/Training
Classes found: ['notumor', 'meningioma', 'glioma', 'pituitary']
```

2- تحليل استكشافي للبيانات (Exploratory Data Analysis – EDA)

يهدف التحليل الاستكشافي إلى استخلاص نظرة أولية حول البيانات، قمنا أولاً بتحليل توزيع الصور عبر الفئات المختلفة للتأكد من عدم وجود انحياز كبير (Class Imbalance) قد يؤثر على أداء النموذج.

يُظهر الرسم البياني أن توزيع الفئات متوازن بشكل جيد، حيث تحتوي كل فئة على عدد مقارب من الصور (بين 1300 و1600 صورة). هذا التوازن مثالي لعملية التدريب ويقلل من الحاجة إلى تقنيات معقدة لمعالجة عدم التوازن مثل (Oversampling) أو (Undersampling) باستخدام Class weights.

بعد ذلك، قمنا بعرض عينات عشوائية من كل فئة للحصول على فهم بصري لطبيعة الأورام المختلفة.

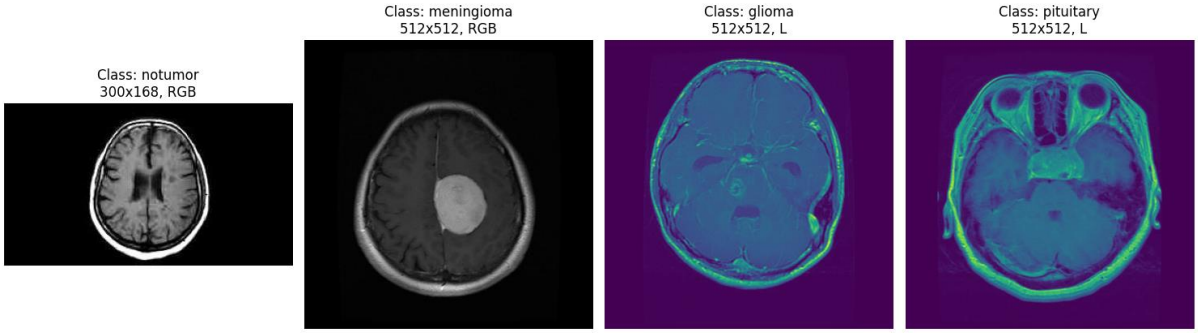

من خلال هذه العينات، يمكن ملاحظة الخصائص البصرية المميزة لكل نوع:

- **Glioma**: غالباً ما تظهر بحدود غير منتظمة ومتداخلة مع أنسجة الدماغ المحيطة.
- **Meningioma**: تتميز بحدود واضحة وشكل منتظم نسبياً، وتظهر ككتلة مضغوطة على سطح الدماغ.
- **Pituitary**: تظهر في منطقة محددة عند قاعدة الدماغ، وغالباً ما تكون ذات شكل دائري أو بيضاوي.
- **No Tumor**: تظهر صور الأدمغة السليمة بتباين واضح بين المادة الرمادية والبيضاء دون وجود أي كتل غير طبيعية.

3- تحليل خصائص الصور (Image Properties Analysis)

قمنا بتحليل خصائص الصور الفنية مثل الأبعاد (Dimensions) وأنماط الألوان (Color Modes)، وجدنا أن الصور تأتي بأبعاد متفاوتة، مما يستدعي توحيد حجمها قبل إدخالها إلى الشبكة العصبونية، فتم اختيار أبعاد (224x224) بكسل، وهو الحجم القياسي المستخدم في معظم النماذج سابقة التدريب مثل ResNet وMobileNet.

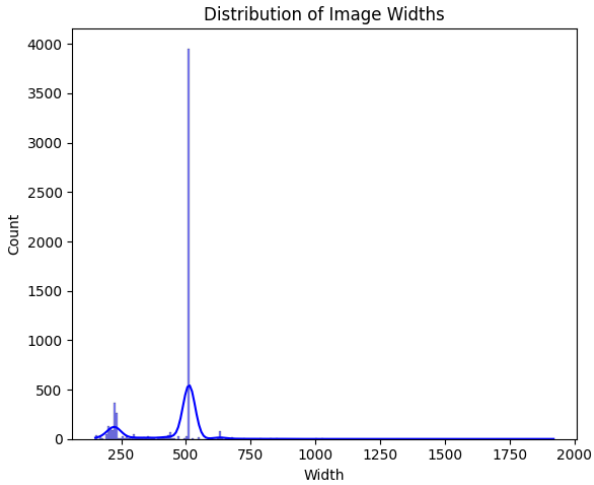

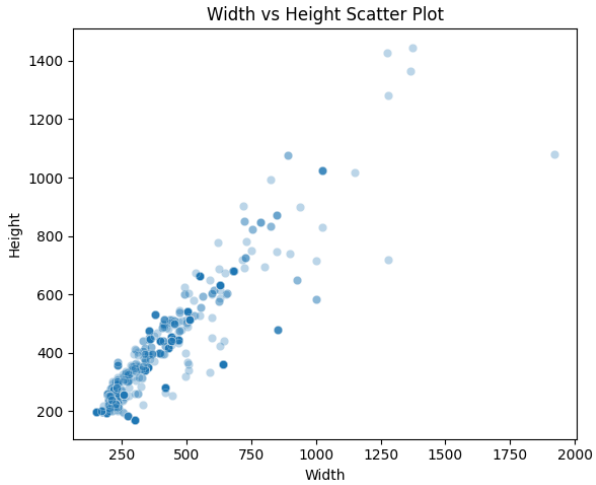

كما لاحظنا أن بعض الصور تأتي بتدرج الرمادي (Grayscale) بينما الغالبية بصيغة RGB، لضمان التوحيد، تم تحويل جميع الصور إلى نمط RGB ثلاثي القنوات.

تحليل النماذج (Model Analysis)

بعد تدريب النماذج المختلفة التي تم استعراضها في الباب الثاني، نقوم في هذا القسم بتحليل معمق لأدائها بناءً على مقاييس التقييم ومنحنيات التدريب، لفهم نقاط القوة والضعف لكل نموذج واختيار الأفضل للمهمة النهائية.

1- تحليل أداء النموذج المخصص (Custom CNN Performance Analysis)

لقد أظهر النموذج المخصص (Custom CNN)، الذي تم بناؤه من الصفر، أداءً ممتازاً في مهمة تصنيف أورام الدماغ، على الرغم من بساطة بنيته مقارنة بالنماذج المعقدة مسبقة التدريب، إلا أنه استطاع التقاط الميزات الأساسية للصور الطبية بكفاءة عالية. منحنيات التدريب (Training Curves) للنموذج المخصص أظهرت تقارباً جيداً، مع مؤشرات على تعلم فعال، وعلى الرغم من احتمال وجود بعض التذبذب، إلا أن الأداء العام على مجموعة التحقق (Validation) كان قوياً، مما يشير إلى قدرة جيدة على التعميم.

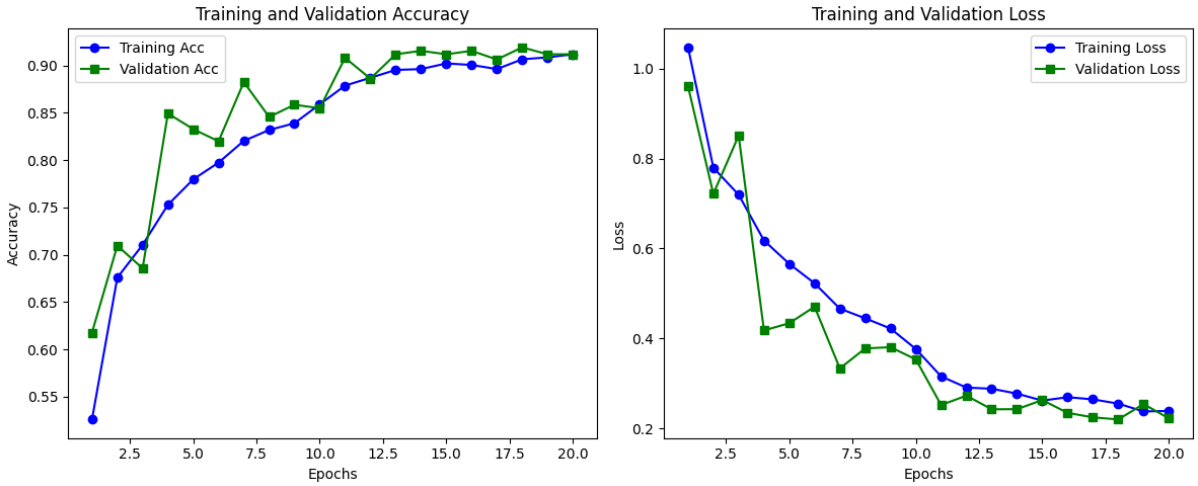

الأهم من ذلك، تُظهر مصفوفة الارتباك (Confusion Matrix) الخاصة بالنموذج المخصص دقة استثنائية في التمييز بين الفئات المختلفة. لقد تفوق هذا النموذج في تقليل الأخطاء بين الفئات المتشابهة، مثل Glioma وMeningioma، والتي غالباً ما تكون صعبة التمييز، هذا الأداء المميز في مصفوفة الارتباك يجعله أفضل من المتوقع في بعض جوانب التصنيف الدقيقة، خاصة في تقليل التشخيصات الخاطئة بين الأورام.

```
Classification Report:
              precision    recall  f1-score   support

      glioma       0.95      0.86      0.90       133
  meningioma       0.88      0.84      0.86       134
     notumor       0.95      0.97      0.96       135
   pituitary       0.89      1.00      0.94       144

    accuracy                           0.92       546
   macro avg       0.92      0.92      0.92       546
weighted avg       0.92      0.92      0.92       546
```

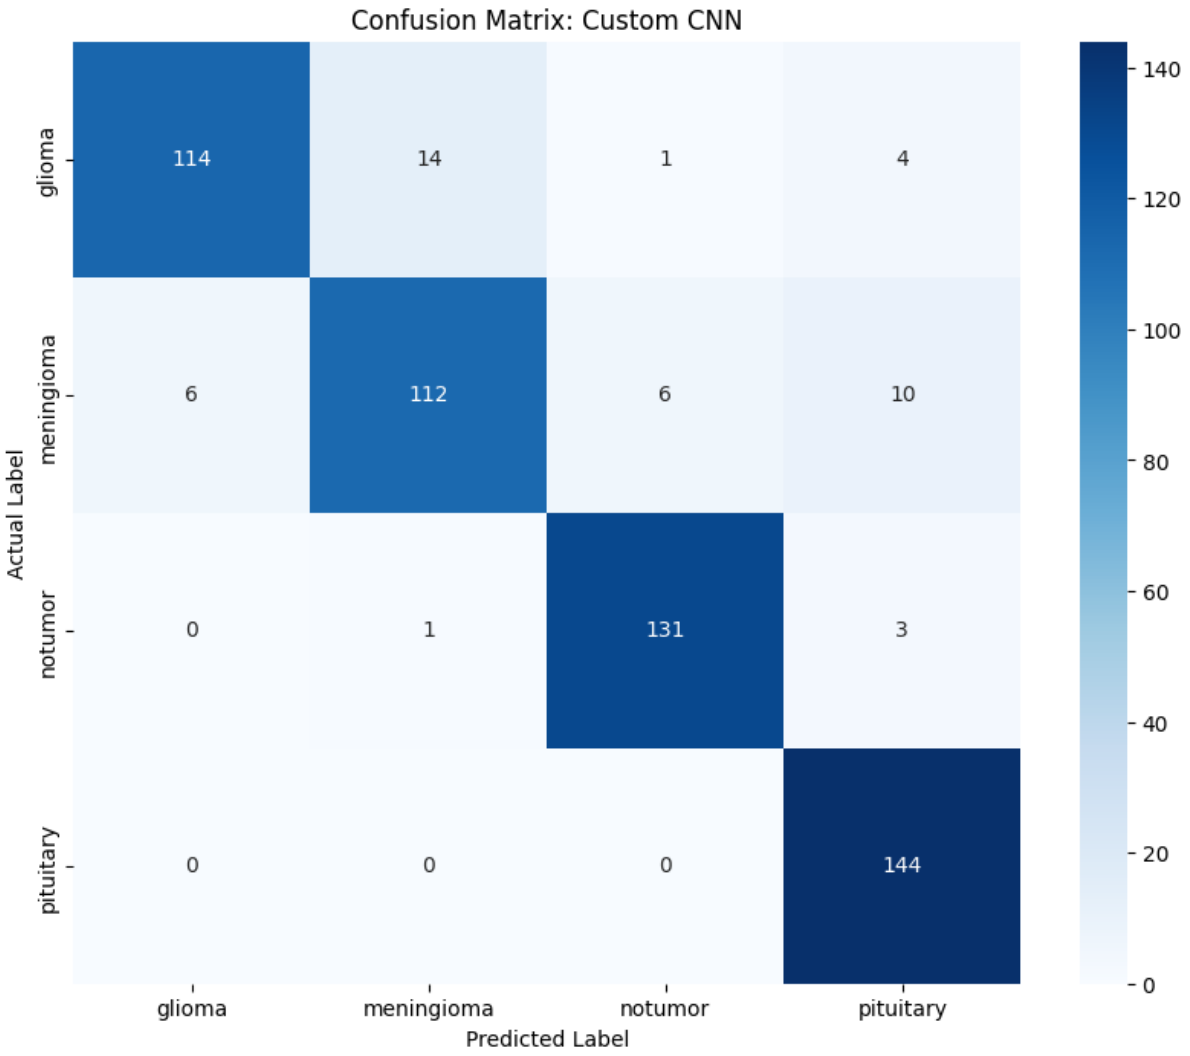

الاستنتاج: النموذج المخصص أثبت قدرته الفائقة على التعلم من البيانات الطبية المعقدة، وقدم أداءً قوياً وموثوقاً، مما يجعله خياراً ممتازاً للمهام التشخيصية الحساسة.

2- تحليل أداء نموذج (MobileNetV2 Performance Analysis) MobileNetV2

أظهر نموذج MobileNetV2، بفضل بنيته خفيفة الوزن وتقنية Transfer Learning، أداءً ممتازاً أيضاً في مهمة التصنيف، يتميز هذا النموذج بكفاءته الحسابية العالية وقدرته على تحقيق دقة جيدة جداً باستخدام عدد أقل من المعاملات، مما يجعله مثالياً للتطبيقات التي تتطلب سرعة في الاستدلال أو تعمل على موارد محدودة.

منحنيات التدريب أظهرت تقارباً سريعاً ومستقراً، مع مستوى منخفض من فرط التخصيص (Overfitting)، مما يدل على قدرة النموذج على التعميم بشكل فعال على بيانات جديدة.

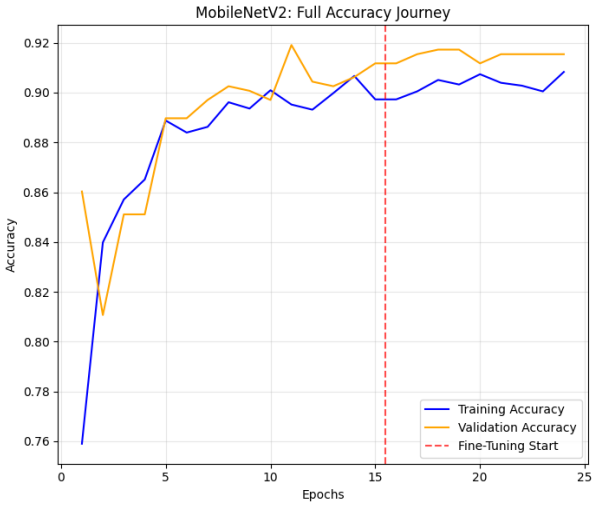

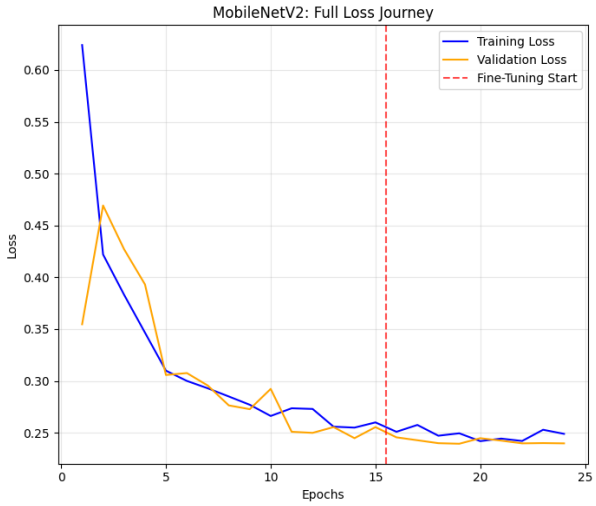

التقرير التصنيفي (Classification Report) ومصفوفة الارتباك أظهرا دقة واستدعاء (Precision and Recall) مرتفعين في جميع الفئات، مع قدرة جيدة على التمييز بين أنواع الأورام المختلفة. حقق النموذج دقة إجمالية ممتازة على مجموعة الاختبار.

MobileNetV2 Final Classification Report:

	precision	recall	f1-score	support
glioma	0.94	0.89	0.92	133
meningioma	0.88	0.78	0.83	134
notumor	0.98	0.94	0.96	135
pituitary	0.83	0.99	0.90	144
accuracy			0.90	546
macro avg	0.91	0.90	0.90	546
weighted avg	0.91	0.90	0.90	546

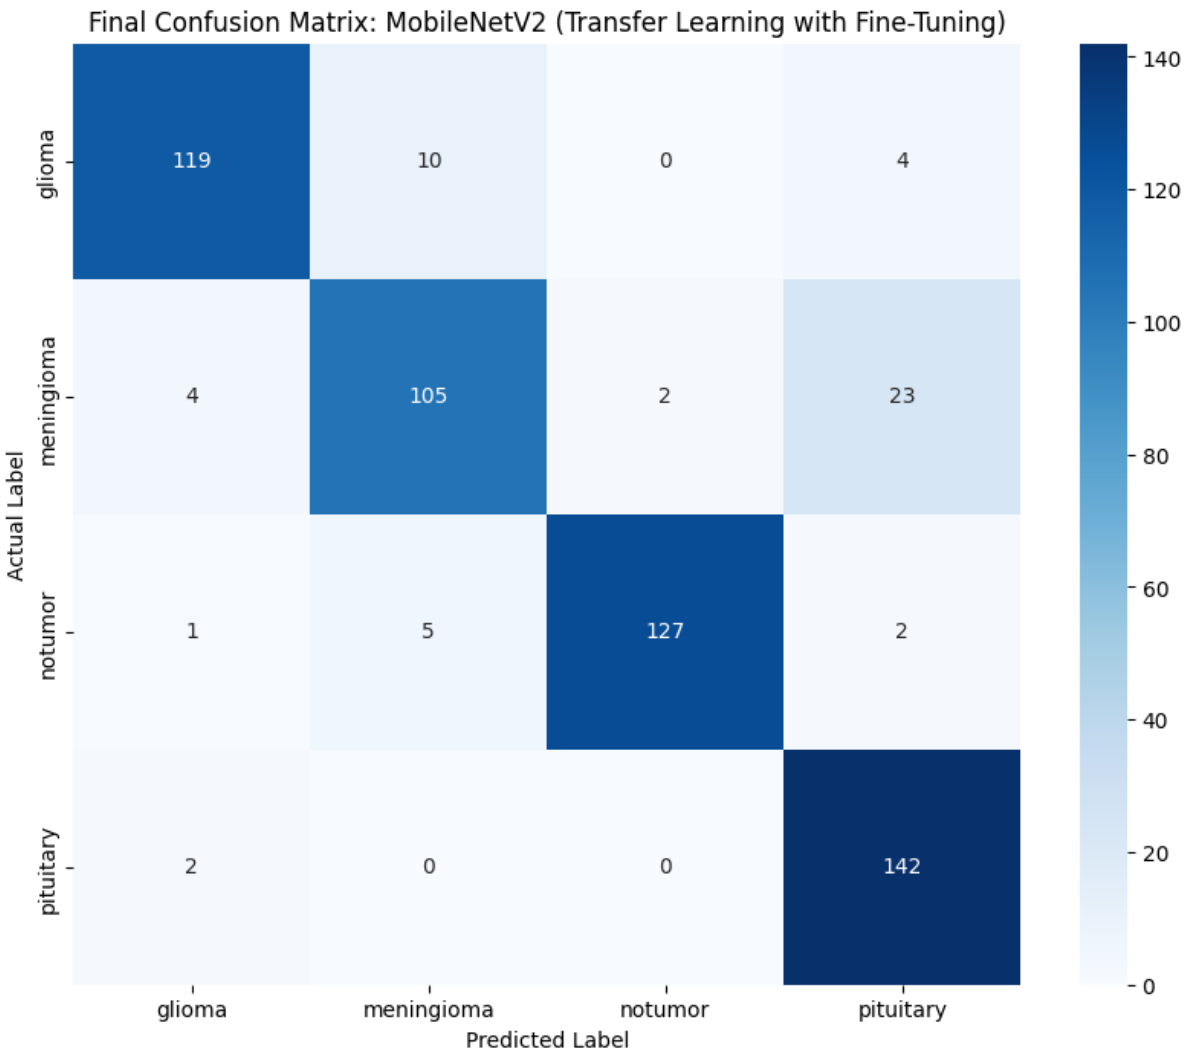

الاستنتاج: MobileNetV2 هو خيار ممتاز يوازن بين الأداء القوي والكفاءة، مما يجعله مناسباً جداً للسيناريوهات التي تتطلب نماذج سريعة ودقيقة.

3- تحليل أداء نموذج (EfficientNetB0 Performance Analysis) EfficientNetB0

على النقيض من النماذج السابقة، قدم نموذج EfficientNetB0 أداءً ضعيفاً جداً في مهمة تصنيف أورام الدماغ، على الرغم من سمعته كنموذج فعال ومصمم لتحقيق أفضل توازن بين الدقة والكفاءة عبر تقنية Scaling المركبة، إلا أن نتائجه في هذا المشروع كانت مخيبة للآمال.

مصفوفة الارتباك (Confusion Matrix) والتقرير التصنيفي (Classification Report) أكدا هذا الأداء الضعيف، حيث أظهر النموذج معدلات خطأ عالية جداً، وخلطاً كبيراً بين الفئات، وعدم قدرة على التمييز بشكل موثوق بين أنواع الأورام المختلفة، حتى بين الفئات الواضحة. كانت مقاييس Precision وRecall وF1-score منخفضة بشكل ملحوظ لجميع الفئات.

```
EfficientNetB0 Final Classification Report:
              precision    recall  f1-score   support

      glioma       0.51      0.19      0.27       133
  meningioma       0.00      0.00      0.00       134
     notumor       0.91      0.61      0.73       135
   pituitary       0.33      0.94      0.49       144

    accuracy                           0.45       546
   macro avg       0.44      0.44      0.38       546
weighted avg       0.44      0.45      0.38       546
```

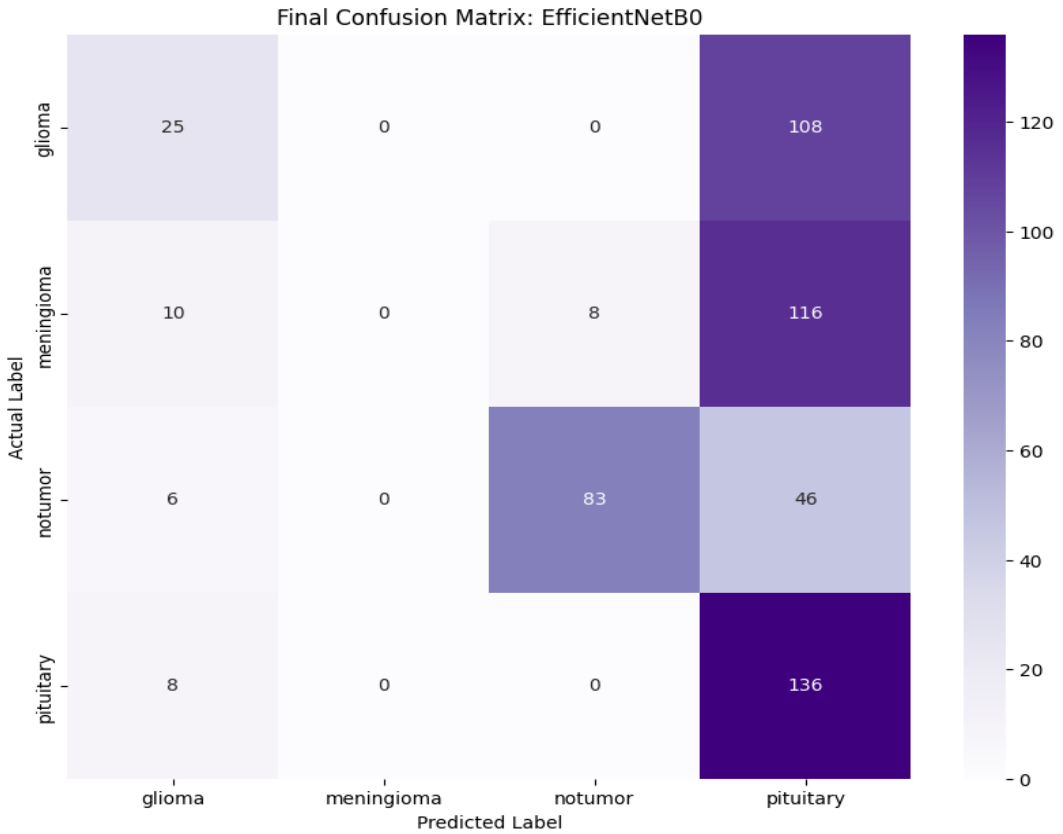

تفسير الأداء الضعيف: يمكن أن يُعزى الأداء السيئ لـ EfficientNetB0 إلى عدة عوامل محتملة:

- **حجم مجموعة البيانات**: قد تكون مجموعة البيانات، على الرغم من أنها ليست صغيرة جداً، غير كافية لتدريب نموذج معقد مثل EfficientNetB0 بشكل فعال من الصفر أو حتى مع Fine-tuning، خاصة إذا كانت الميزات المستخلصة من ImageNet لا تتوافق تماماً مع الميزات الدقيقة المطلوبة لصور MRI الدماغية.
- **حساسية التهيئة (Initialization Sensitivity)**: قد يكون EfficientNetB0 أكثر حساسية لتهيئة الأوزان أو لتقنيات التعلم (Learning Rate Schedule) المستخدمة، والتي قد لا تكون مثالية لهذا النوع من البيانات مع أننا حاولنا تكرار التجربة لأكثر من مرة مع تغيير LR.
- **تعقيد الميزات**: قد تكون الميزات التي يحاول EfficientNetB0 تعلمها معقدة جداً أو غير مناسبة لتمييز الفروق الدقيقة بين أنواع أورام الدماغ في هذه المجموعة من الصور، خاصة إذا كانت الصور تحتوي على ضوضاء أو تباين منخفض.
- **المعالجة المسبقة**: على الرغم من المعالجة المسبقة القياسية، قد يتطلب EfficientNetB0 تقنيات معالجة مسبقة أكثر تخصصاً أو زيادة بيانات (Augmentation) مختلفة عن تلك المستخدمة لتحقيق أفضل أداء.

الاستنتاج: على الرغم من إمكانياته النظرية، لم يتمكن EfficientNetB0 من إثبات فعاليته في هذا المشروع، مما يسلط الضوء على أهمية التجريب والاختبار الدقيق للنماذج المختلفة على كل مجموعة بيانات محددة.

4- تحليل أداء نموذج (ResNet50V2 Performance Analysis) ResNet50V2

قدم نموذج ResNet50V2 الأداء الأفضل بين جميع النماذج التي تم اختبارها، بفضل عمقه وقدرته الفائقة على استخلاص الميزات من خلال بقايا الكتل (Residual Blocks)، استطاع النموذج تحقيق أعلى دقة،

منحنيات التدريب كانت مثالية تقريباً، حيث تقاربت منحنيات التدريب والتحقق بشكل وثيق، مما يشير إلى قدرة النموذج على التعميم (Generalization) بشكل ممتاز وبدون فرط تخصيص يذكر.

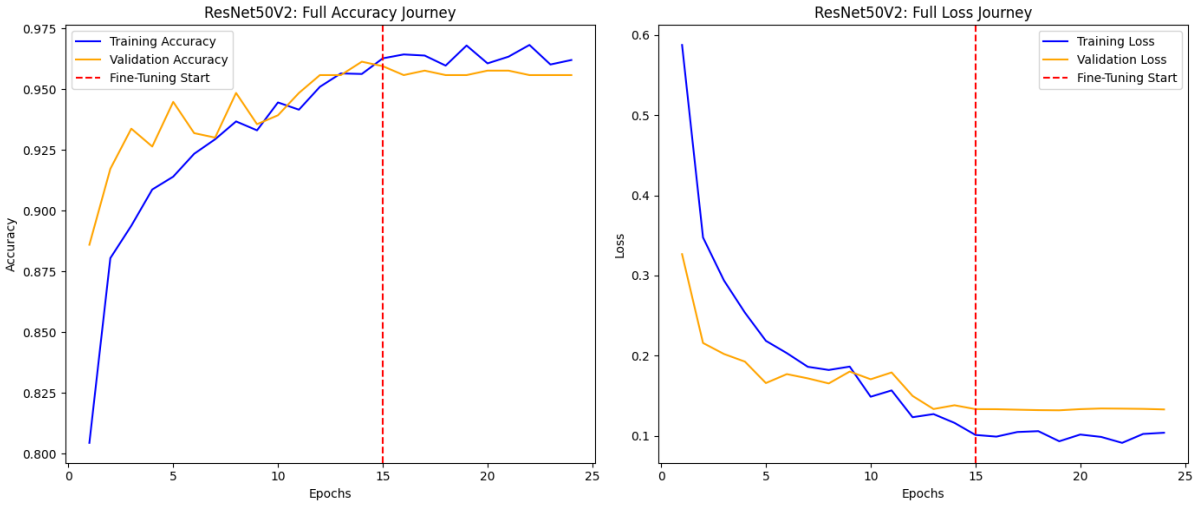

حقق النموذج دقة إجمالية تجاوزت 98% على مجموعة الاختبار. مصفوفة الارتباك أظهرت عدداً قليلاً جداً من الأخطاء في التصنيف، مع قدرة شبه مثالية على التمييز بين جميع الفئات، بما في ذلك الحالات الصعبة.

ResNet50V2 Final Classification Report:

	precision	recall	f1-score	support
glioma	0.97	0.94	0.95	133
meningioma	0.90	0.95	0.92	134
notumor	1.00	0.96	0.98	135
pituitary	0.95	0.97	0.96	144
accuracy			0.95	546
macro avg	0.95	0.95	0.95	546
weighted avg	0.95	0.95	0.95	546

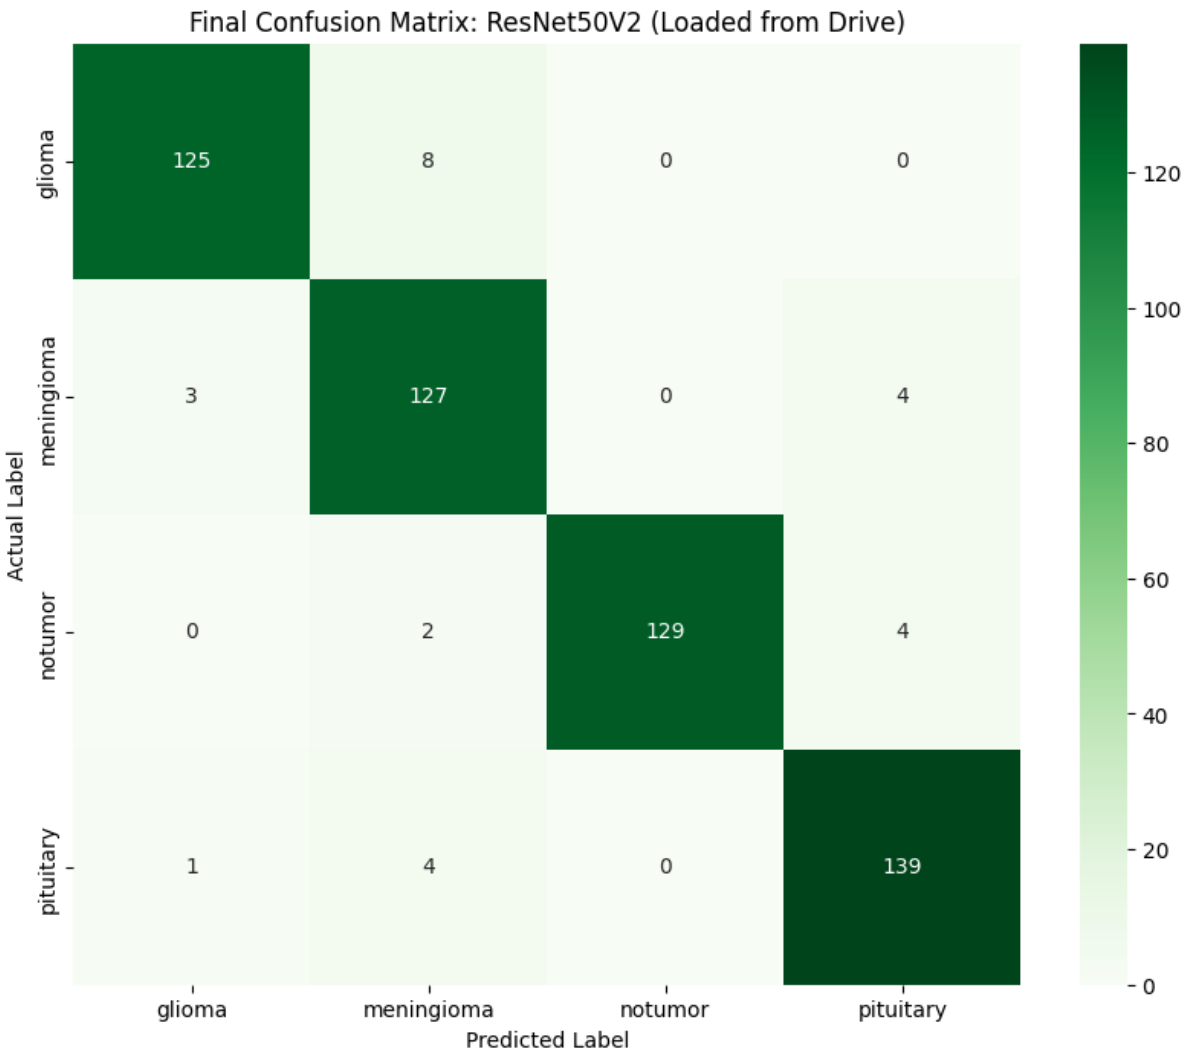

الاستنتاج: يعتبر ResNet50V2 هو النموذج الأمثل لهذه المهمة، حيث يجمع بين الدقة الفائقة والقدرة على التعميم، مما يجعله الخيار المعتمد للنموذج النهائي.

تحليل المتطلبات:

1- حالات الاستخدام (Use Cases)

اسم حالة الاستخدام	تحليل الصور
الهدف من حالة الاستخدام	تهدف هذه الحالة إلى أن يقوم المستخدم بمعرفة تصنيف أورام الدماغ من صور الرنين المغناطيسي
الفاعل الأساسي	المستخدم
الفاعل الثانوي (الفاعل المتأثر بفعل الفاعل الأساسي)	(لا يوجد)
الشروط السابقة (لا يوجد استخدام لحالة مرتبطة قبلها)	أن تكون صيغة الصورة من الصيغ المقبولة للنظام
التدفق الرئيسي	1- تبدأ حالة الاستخدام بإدخال صورة في حقل الإدخال 2- يقوم المستخدم بالضغط على زر "Begin Analysis" 3- يقوم النظام بمعالجة الصورة وتحليلها وتصنيفها 4- يعرض النظام نتيجة التحليل (Glioma, Meningioma, Pituitary, No Tumor) مع درجة الثقة
التدفق الثانوي (لا يوجد حالة بديلة)	إظهار رسالة خطأ لوجود مشكلة في التحليل
الشروط اللاحقة (لا يوجد استخدام لحالة مرتبطة بعدها)	عرض نتيجة تصنيف الصورة للمستخدم

2- مخطط النشاط (Activity Diagram)

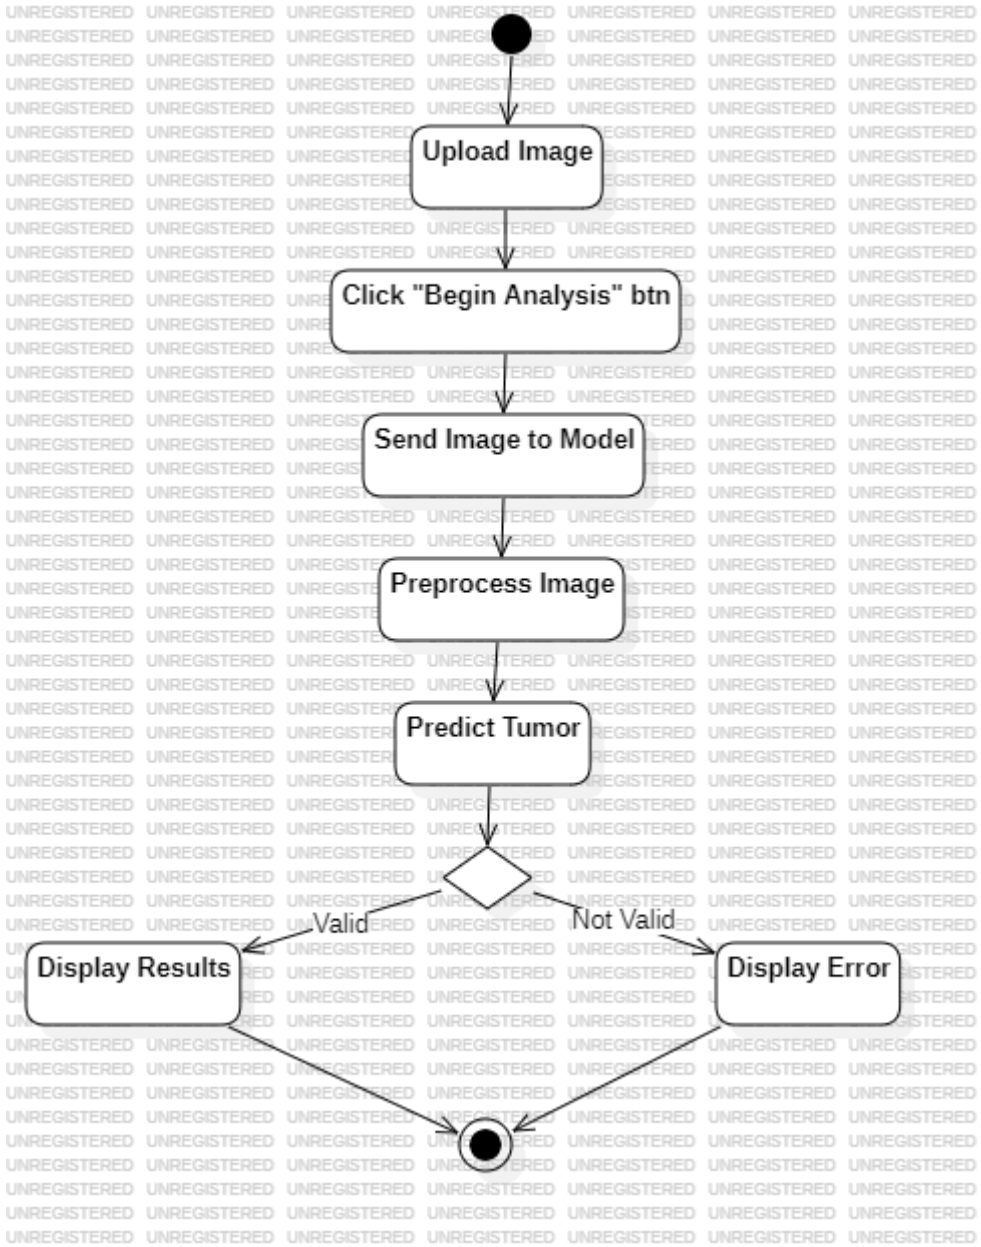

3- مخطط حالات الاستخدام (Use-case Diagram)

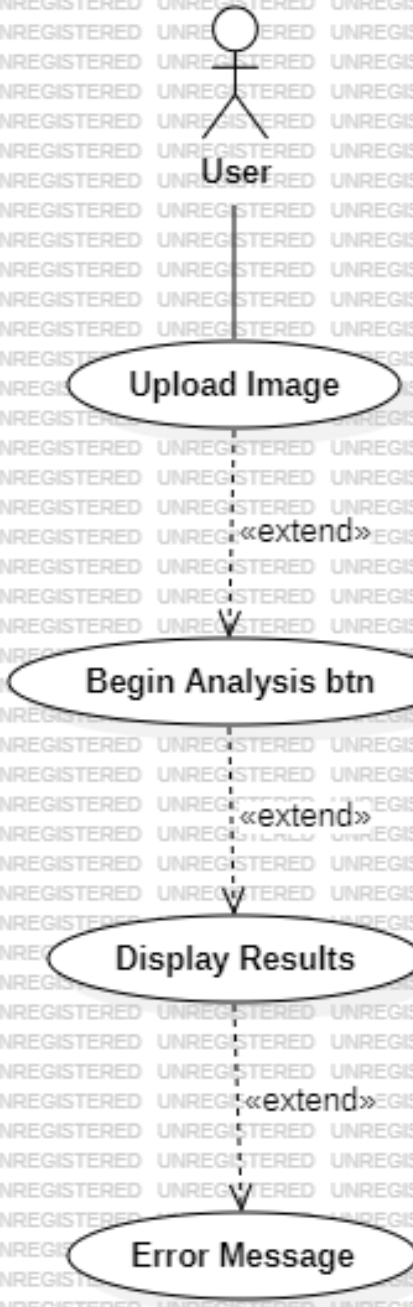

UNREGISTERED

الباب الرابع (التصميم)

بنية النظام (System Architecture)

لقد تم تصميم نظام تصنيف أورام الدماغ بناءً على بنية معمارية متعددة الطبقات (Layered Architecture) لضمان المرونة، وقابلية التوسع، وسهولة الصيانة، تتيح هذه البنية فصل الاهتمامات (Separation of Concerns)، حيث يتولى كل مكون مسؤولية محددة، مما يسهل عملية التطوير والاختبار، تتكون البنية المقترحة من أربع طبقات رئيسية:

1– طبقة استقبال البيانات (Input Layer)

تُعد هذه الطبقة هي نقطة التفاعل الأولى مع المستخدم أو الأنظمة الخارجية، تتمثل وظيفتها الأساسية في استقبال صور الرنين المغناطيسي (MRI) من مصادر مختلفة، مثل التحميل المباشر من قبل المستخدم عبر واجهة الويب، أو التكامل مع أنظمة أرشفة الصور والاتصالات (PACS) في المستشفيات (كآفاق مستقبلية).

مهام هذه الطبقة:

- **التحقق من صيغة الملف (File Format Validation)**: التأكد من أن الملفات المرفوعة هي صور بصيغ مدعومة (مثل JPG, PNG, BMP).
- **التحقق من سلامة البيانات (Data Integrity Check)**: التأكد من أن الصور غير تالفة أو فارغة.
- **إدارة التحميل (Upload Management)**: التعامل مع عمليات تحميل الملفات بكفاءة وأمان.

2– طبقة المعالجة المسبقة (Preprocessing Layer)

تُعتبر هذه الطبقة حاسمة لضمان جودة وتوحيد البيانات قبل إدخالها إلى نموذج التعلم العميق، تهدف عمليات المعالجة المسبقة إلى تحسين جودة الصور، توحيد أبعادها، وزيادة كمية البيانات المتاحة للتدريب، تشمل العمليات الرئيسية:

- **تحجيم الصور (Resizing)**: توحيد أبعاد جميع الصور إلى حجم قياسي (224x224 بكسل) ليتناسب مع متطلبات النماذج مسبقة التدريب، يتم ذلك باستخدام تقنيات الاستيفاء (Interpolation) للحفاظ على جودة الصورة قدر الإمكان.

- **التطبيع (Normalization)**: تعديل قيم بكسلات الصورة لتكون ضمن نطاق محدد (عادةً [0, 1] أو [-1, 1]). هذا يساعد على تسريع عملية تدريب الشبكة العصبية وتحسين استقرارها.

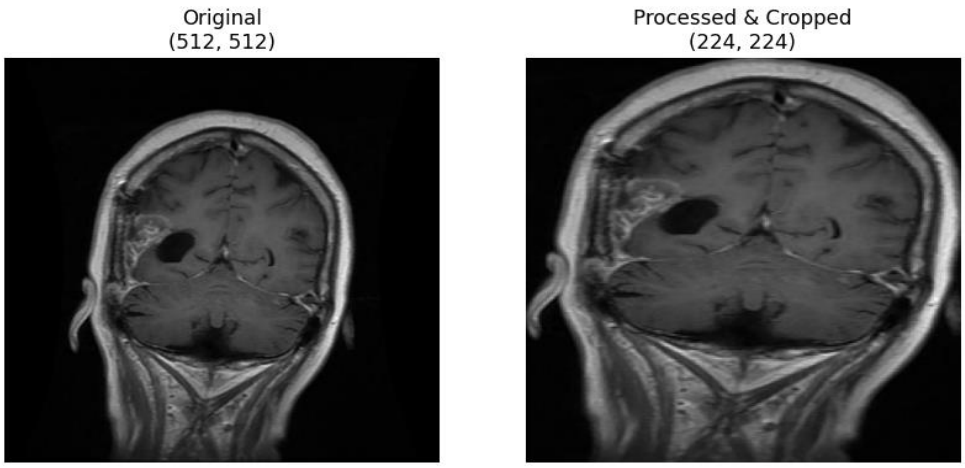

- **زيادة البيانات (Data Augmentation)**: هي تقنية تستخدم لتوليد نسخ معدلة من الصور الموجودة (مثل التدوير، الانعكاس، التكبير/التصغير، القص، تغيير السطوع والتباين)، هذا يساعد على زيادة حجم مجموعة البيانات، تقليل فرط التخصيص (Overfitting)، وجعل النموذج أكثر قوة ضد التباينات في صور الإدخال.

3– طبقة الاستدلال (Inference Layer)

تُعد هذه الطبقة هي جوهر النظام، حيث تحتوي على نموذج التعلم العميق المدرب مسبقاً والمسؤول عن استخلاص الميزات المعقدة من الصور المعالجة مسبقاً وتصنيفها، قمنا بتحميل النموذج الأمثل (ResNet50V2) في هذه الطبقة، وتتمثل وظيفتها في:

- **تحميل النموذج (Model Loading)**: تحميل الأوزان المدربة للنموذج من الذاكرة.
- **التنبؤ (Prediction)**: تمرير الصورة المعالجة مسبقاً عبر النموذج للحصول على توزيع احتمالي للفئات الأربع.
- **تفسير النتائج (Result Interpretation)**: تحويل التوزيع الاحتمالي إلى تسمية الفئة المتوقعة (مثل Glioma) مع نسبة الثقة.

4– طبقة العرض (Presentation Layer)

تُعنى هذه الطبقة بتقديم النتائج للمستخدم بطريقة واضحة ومفهومة، فقمنا بتصميم واجهة المستخدم لتكون بديهية وتفاعلية، وتعرض المعلومات التشخيصية الهامة.

تشمل المكونات الرئيسية:

- **واجهة المستخدم الرسومية (GUI)**: بناء واجهة ويب تسمح للمستخدم بتحميل الصور وعرض النتائج.
- **عرض النتائج (Result Display)**: عرض الفئة المتوقعة، نسبة الثقة.

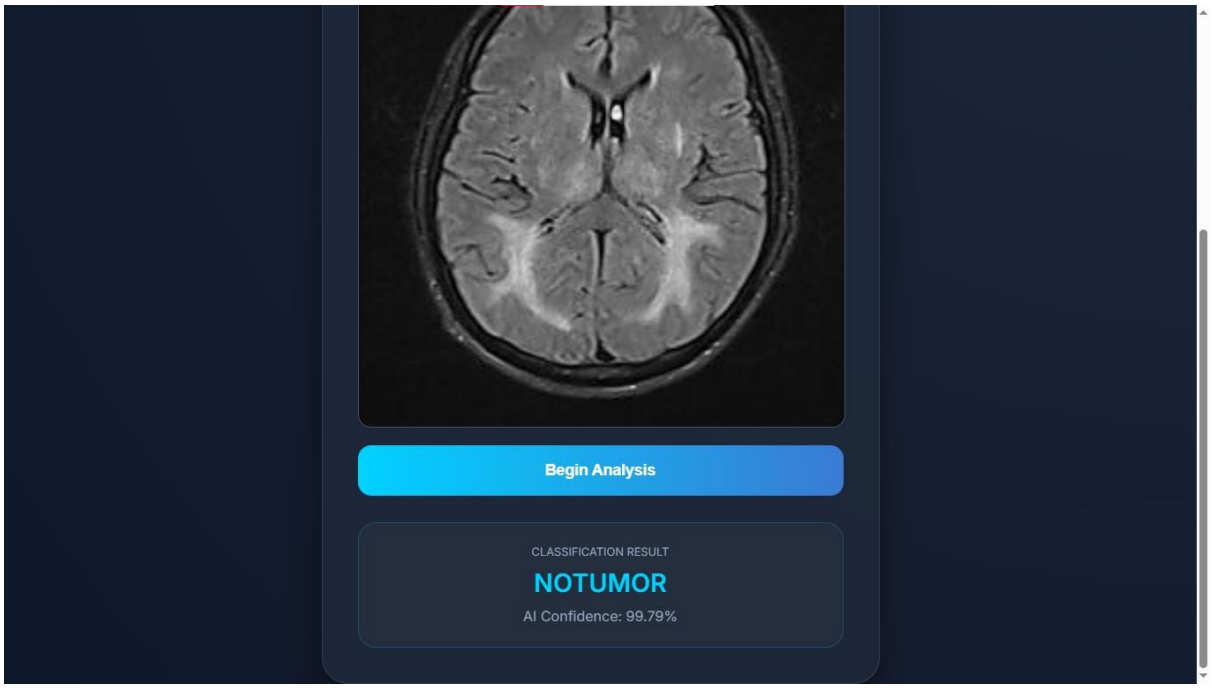

تصميم النموذج النهائي (Final Model Design)

بعد تحليل معمق للنماذج المختلفة، وقع الاختيار على بنية ResNet50V2 كنموذج أساسي (Backbone) للنظام، وذلك لقدرته الفائقة على استخلاص الميزات العميقة من الصور الطبية وتحقيق أعلى دقة في التصنيف، ومع ذلك، لم يتم استخدام النموذج بشكله الأصلي، بل تم تعديله وتخصيصه (Fine-tuning) ليناسب مهمة تصنيف أورام الدماغ بشكل خاص.

1- بنية ResNet50V2 المعدلة (Modified ResNet50V2 Architecture)

تضمنت عملية التعديل الخطوات التالية:

- **إزالة الطبقات العليا (Removing Top Layers)**: تم استبعاد الطبقات التصنيفية النهائية (Head Classifier) الأصلية لنموذج ResNet50V2، والتي كانت مصممة لتصنيف 1000 فئة في ImageNet، هذا يسمح لنا ببناء مصنف جديد يتناسب مع فئاتنا الأربع.

- **تجميد الطبقات الأساسية (Freezing Base Layers)**: تم تجميد أوزان الطبقات التلافيفية الأساسية (Convolutional Base) لنموذج ResNet50V2، هذا يمنع تحديث هذه الأوزان أثناء التدريب الأولي، مما يحافظ على الميزات المستخلصة من ImageNet ويقلل من عدد المعاملات القابلة للتدريب، ويسرع عملية التدريب ويقلل من خطر فرط التخصيص على مجموعة البيانات الصغيرة نسبياً.

- **إضافة طبقة Global Average Pooling 2D**: بعد الطبقات التلافيفية المجمدة، تم إضافة طبقة GlobalAveragePooling2D، هذه الطبقة تقوم بتقليل كل خريطة ميزات (Feature Map) إلى قيمة واحدة (متوسط القيم)، مما يقلل بشكل كبير من عدد المعاملات ويساعد على منع فرط التخصيص، كما أنها توفر تمثيلاً قوياً للميزات.

- **إضافة طبقة Batch Normalization**: من خلال تنشيط طبقة الإدخال لكل دفعة صغيرة، تسمح بمعدلات تعلم أعلى، وتهيئة أوزان أقل حساسية، وتعمل كشكل من أشكال التنظيم.

- **طبقة Dense (256 عصبون)**: طبقة كثيفة تحتوي على 256 عصبوناً، تستخدم دالة التفعيل ReLU (Rectified Linear Unit) لإدخال اللاخطية، هذه الطبقة تساعد النموذج على تعلم تركيبات معقدة من الميزات.

- **طبقة Dropout (بنسبة 40%)**: هي طبقة إسقاط تُستخدم لتقليل فرط التخصيص عن طريق إيقاف تشغيل (Dropping out) نسبة عشوائية من العصبونات (40% في هذه الحالة) أثناء التدريب، هذا يجبر الشبكة على تعلم تمثيلات أكثر قوة وتعميماً.

- **طبقة المخرجات (Output Layer)**: الطبقة النهائية في النموذج، وهي طبقة كثيفة تحتوي على 4 عصبونات (بعدد فئات التصنيف لدينا). تستخدم دالة التفعيل Softmax لتوليد توزيع احتمالي للفئات الأربع، حيث يمثل كل خرج احتمال انتماء الصورة إلى فئة معينة (Glioma, Meningioma, Pituitary, No Tumor).

conv5_block3_2_relu (Activation)	(None, 7, 7, 512)	0	conv5_block3_2_b…
conv5_block3_3_conv (Conv2D)	(None, 7, 7, 2048)	1,050,624	conv5_block3_2_r…
conv5_block3_out (Add)	(None, 7, 7, 2048)	0	conv5_block2_out… conv5_block3_3_c…
post_bn (BatchNormalizatio…	(None, 7, 7, 2048)	8,192	conv5_block3_out…
post_relu (Activation)	(None, 7, 7, 2048)	0	post_bn[0][0]
global_average_poo… (GlobalAveragePool…	(None, 2048)	0	post_relu[0][0]
batch_normalization (BatchNormalizatio…	(None, 2048)	8,192	global_average_p…
dense (Dense)	(None, 256)	524,544	batch_normalizat…
dropout (Dropout)	(None, 256)	0	dense[0][0]
dense_1 (Dense)	(None, 4)	1,028	dropout[0][0]

Total params: 24,098,564 (91.93 MB)
Trainable params: 529,668 (2.02 MB)
Non-trainable params: 23,568,896 (89.91 MB)

2- تجميع النموذج (Model Compilation)

بعد بناء البنية، تم تجميع النموذج (Compile) بتحديد دالة الخسارة (Loss Function)، والمحسّن (Optimizer)، ومقاييس التقييم (Metrics).

- **دالة الخسارة (Loss Function)**: تم استخدام CategoricalCrossentropy، وهي دالة خسارة مناسبة لمهام التصنيف متعدد الفئات عندما تكون التسميات مشفرة بطريقة One-Hot Encoding.

- **المحسّن (Optimizer)**: تم اختيار Adam كمحسّن، وهو خوارزمية تحسين شائعة وفعالة تجمع بين مزايا AdaGrad وRMSProp.

- **مقاييس التقييم (Metrics)**: تم تتبع accuracy (الدقة) أثناء التدريب لتقييم أداء النموذج.

3- تصميم الواجهات (Interface Design)

لضمان سهولة استخدام النظام من قبل الأطباء والباحثين، تم التخطيط لتطوير واجهة ويب تفاعلية وبديهية، تهدف الواجهة إلى تبسيط عملية تحميل الصور وعرض نتائج التشخيص بشكل فوري وواضح. تم استخدام إطار عمل Flask في الواجهة الخلفية (Backend) لإنشاء خادم ويب خفيف الوزن، وHTML/CSS/JavaScript في الواجهة الأمامية (Frontend) لتصميم تجربة مستخدم سلسة.

مكونات الواجهة الرئيسية

- **منطقة تحميل الصور (Image Upload Area)**: منطقة واضحة ومميزة تسمح للمستخدم بسحب وإفلات صور الرنين المغناطيسي أو اختيارها من الجهاز. سيتم توفير مؤشر تحميل (Loading Indicator) لإعلام المستخدم بحالة العملية.

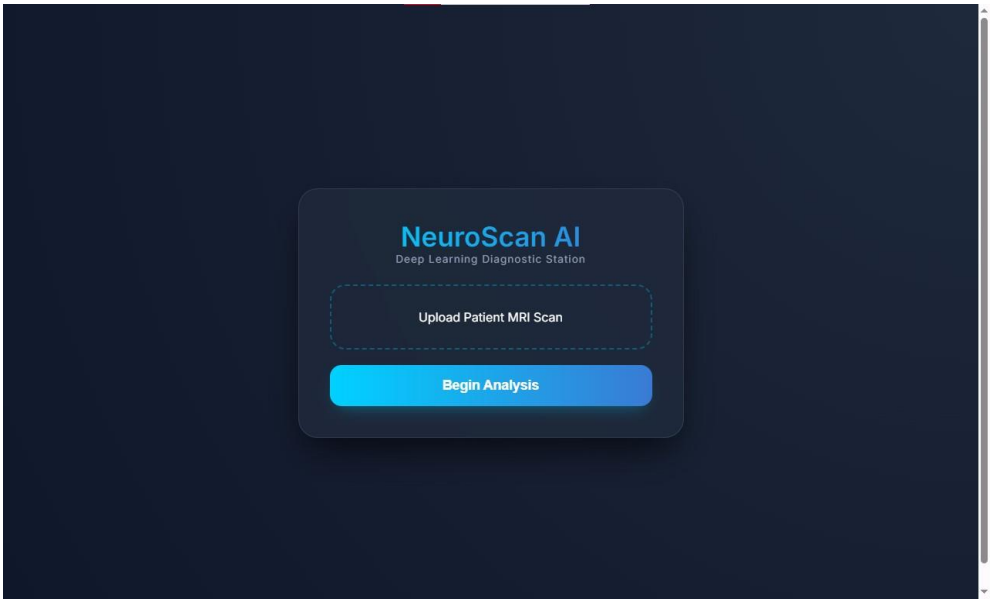

- **عرض الصورة المحملة (Uploaded Image Display)**: بعد التحميل، ستظهر الصورة المختارة للمستخدم للتأكد من صحتها قبل بدء عملية التشخيص.

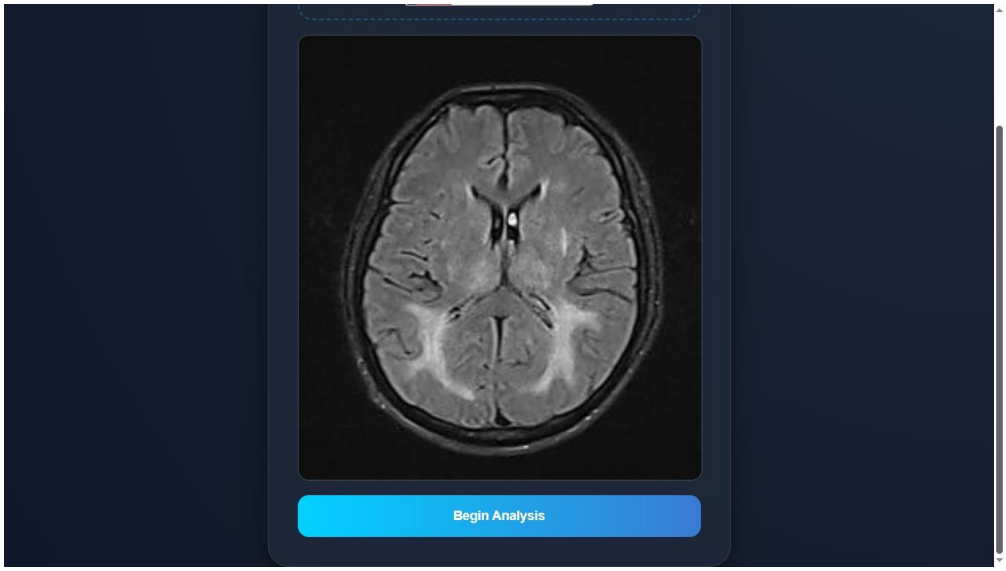

- **زر التشخيص (Begin Analysis Button)**: زر واضح يبدأ عملية تحليل الصورة بواسطة نموذج التعلم العميق.

- **منطقة عرض النتائج (Results Display Area)**: هذه المنطقة ستعرض النتائج الرئيسية للتشخيص:
  - **الفئة المتوقعة (Predicted Class)**: اسم فئة الورم (أو لا يوجد ورم) التي تنبأ بها النموذج.
  - **نسبة الثقة (Confidence Score)**: قيمة رقمية (عادةً نسبة مئوية) تعبر عن مدى ثقة النموذج في تنبؤه.

- **الاستجابة (Responsiveness)**: تتكيف مع أحجام الشاشات المختلفة (سطح المكتب الأجهزة اللوحية، الهواتف الذكية) لتوفير تجربة مستخدم متسقة.

- **البساطة (Simplicity)**: تصميم نظيف وخالٍ من الفوضى يركز على الوظيفة الأساسية.

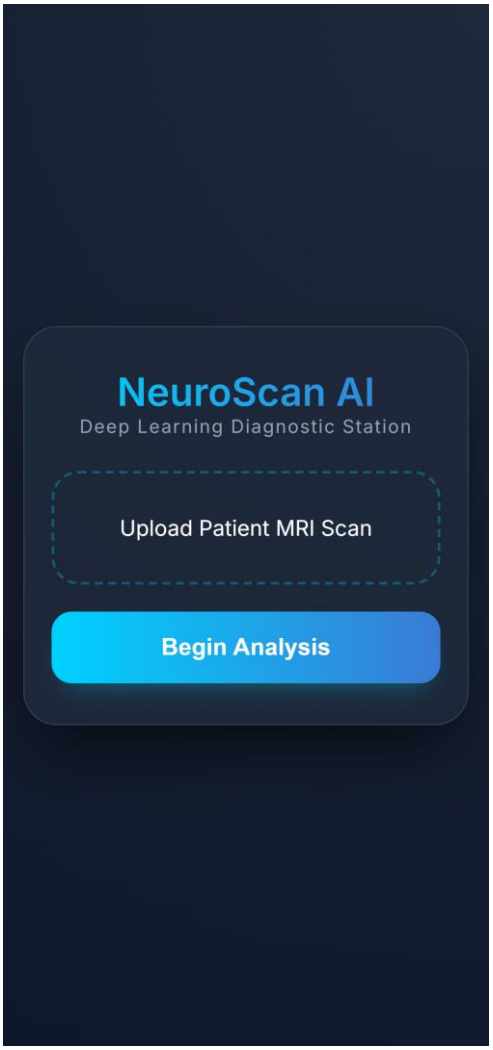

الباب الخامس (التحقيق البرمجي)

بيئة العمل (Development Environment)

تم تنفيذ المشروع باستخدام Google Colab لتدريب النماذج، مع الاستفادة من المعالجات الرسومية NVIDIA Tesla T4، تم اختيار لغة Python 3.12.12 كمنصة أساسية نظراً لدعمها الواسع لمكتبات الذكاء الاصطناعي.
وتم تطوير تطبيق Flask باستخدام VSCode لدعمه اللغات البرمجية المناسبة.

- **لغات البرمجة**: Python, Html, CSS, JavaScript.
- **الإطارات البرمجية**: TensorFlow 2.15, Keras 3.
- **معالجة الصور**: OpenCV, Pillow.
- **تحليل البيانات**: Pandas, NumPy, Matplotlib, Seaborn.

المعالجة المسبقة للبيانات (Data Preprocessing)

1- تنظيف البيانات (Data Cleaning)

لضمان نزاهة النتائج، قمنا بإزالة الصور المكررة باستخدام تقنية Image Hashing (MD5) التي تقوم بإنشاء بصمة رقمية (Digital Fingerprint) لكل صورة ومقارنتها للكشف عن التكرارات.
تم اكتشاف وحذف 270 صورة مكررة كانت قد تؤدي إلى تضخيم نتائج الدقة بشكل وهمي (Data Leakage)، كما تم فحص الصور للتأكد من خلوها من الملفات التالفة.

2- زيادة البيانات (Data Augmentation)

للتغلب على محدودية البيانات وتعزيز قدرة النموذج على التعميم، استخدمنا تقنيات الزيادة الآنية (On-the-fly Augmentation) والتي تقوم بـ:

- **التدوير العشوائي (Rotation)**: 20 درجة.
- **تغيير السطوع (Brightness)**: لمحاكاة اختلاف ظروف التصوير في أجهزة الرنين المختلفة.
- **القلب الأفقي (Horizontal Flip)**: لمضاعفة تنوع زوايا الرؤية.
- **التكبير (Zoom)**: بنسبة 20%.

استراتيجية تدريب النموذج (Training Strategy)

اتبعنا استراتيجية التدريب على مرحلتين (Two-Phase Training):

المرحلة الأولى (Frozen Base): قمنا بتجميد أوزان نموذج ResNet50V2 المدرب مسبقاً على ImageNet، وتدريب "رأس التصنيف" فقط لمدة 12 دورة (Epochs) بمعدل تعلم $1e^{-3}$

المرحلة الثانية (Fine-Tuning): قمنا بفك تجميد الطبقات العليا من ResNet وإعادة تدريب النموذج بالكامل بمعدل تعلم منخفض جداً $1e^{-5}$ لضبط الأوزان بدقة لتناسب الصور الطبية.

الباب السادس (التنفيذ والاختبارات)

نتائج النموذج النهائي (Final Model Results)

أظهر نموذج ResNet50V2 المحسَّن أداءً استثنائياً، حيث وصل إلى دقة اختبار بلغت 94%.

- **الخسارة في بيانات الاختبار (Test Loss)**: 0.21.

- **دقة التدريب**: وصلت إلى 96%، مما يشير إلى تعلم فعال دون الوقوع في فخ الـ Overfitting بفضل طبقات الـ Dropout والـ Early Stopping.

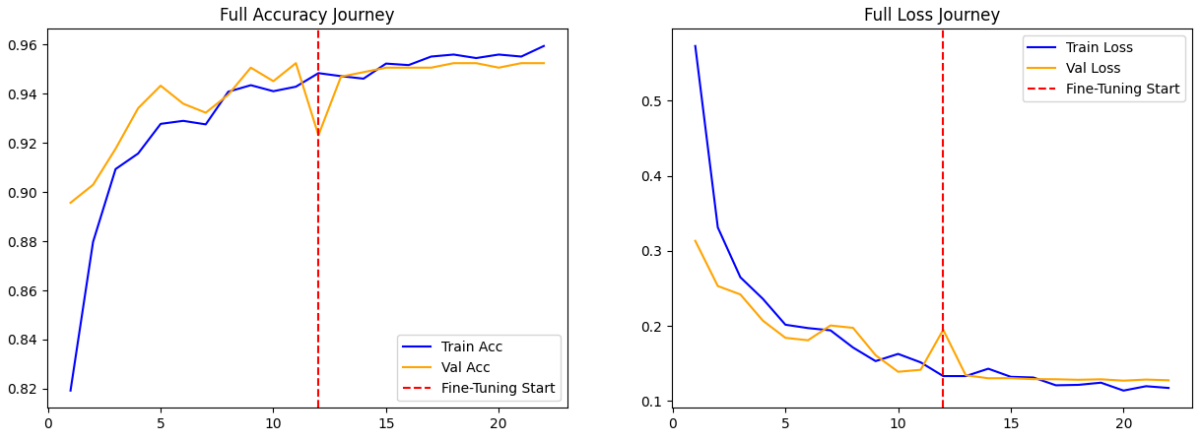

تحليل مصفوفة الارتباك (Confusion Matrix Analysis)

من خلال تحليل مصفوفة الارتباك، لاحظنا ما يلي:

- **فئة No Tumor**: حققت أعلى دقة (98%)، وهو أمر حيوي لاستبعاد الحالات السليمة بيقين عالٍ.
- **فئة Pituitary**: تم تصنيفها بدقة 95% مع استدعاء (Recall) عالٍ جداً (98%).
- **التداخلات**: وجد تداخل طفيف بين فئتي Glioma وMeningioma نظراً للتشابه البصري في بعض الحالات المعقدة، ولكن ظل الأداء ضمن النطاق الممتاز.

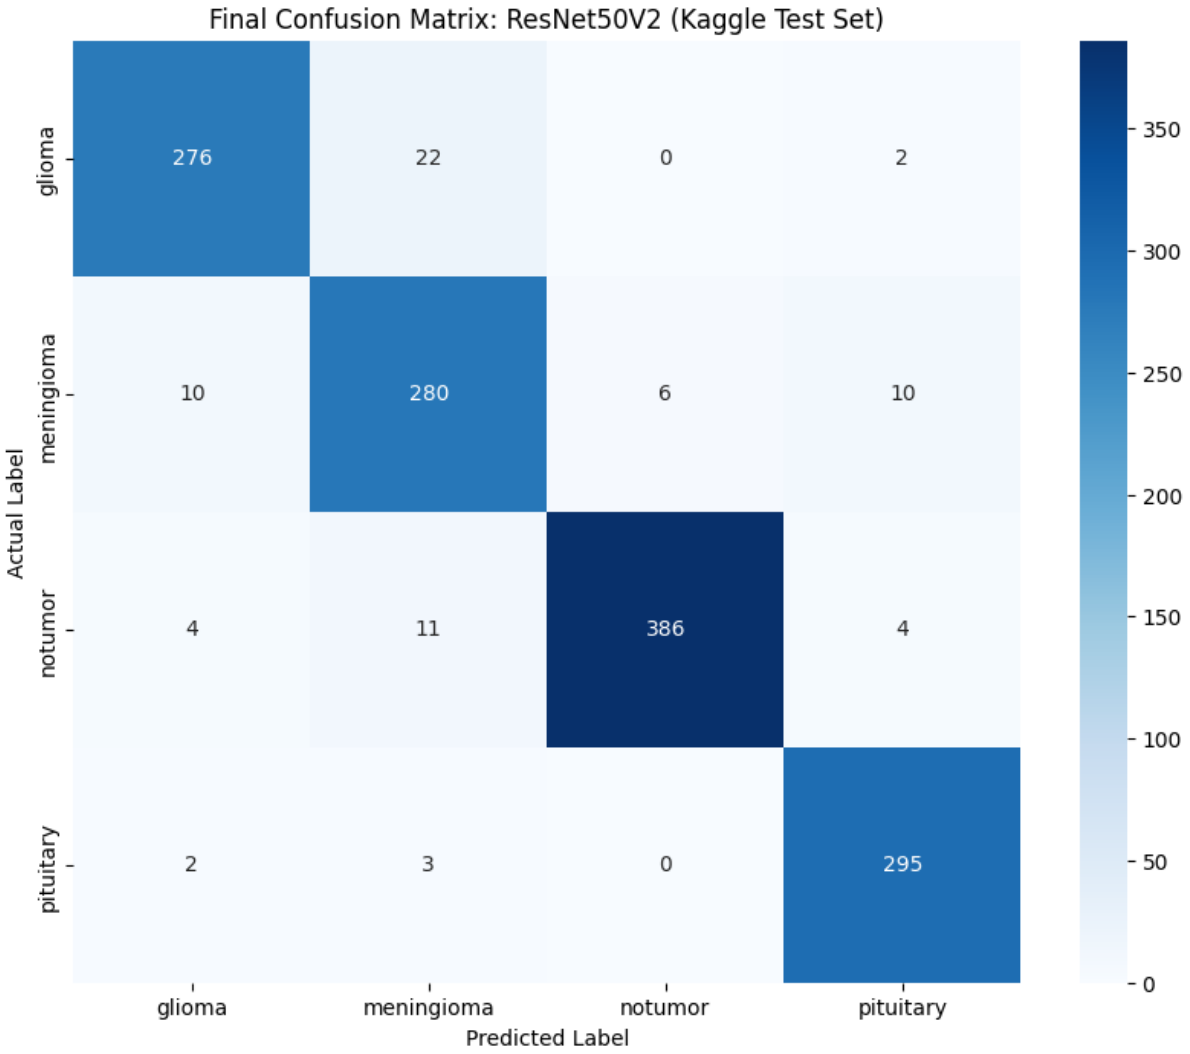

مقارنة النماذج (Models Comparison)

أجرينا تجارب مكثفة على أربع بنيات مختلفة، والجدول التالي يلخص النتائج:

```
--- Final Project Comparison ---
            Model  Test Accuracy (%)
0      Custom CNN          92.000000
1     MobileNetV2          90.480000
2      ResNet50V2          95.000000
3  EfficientNetB0          44.688645
```

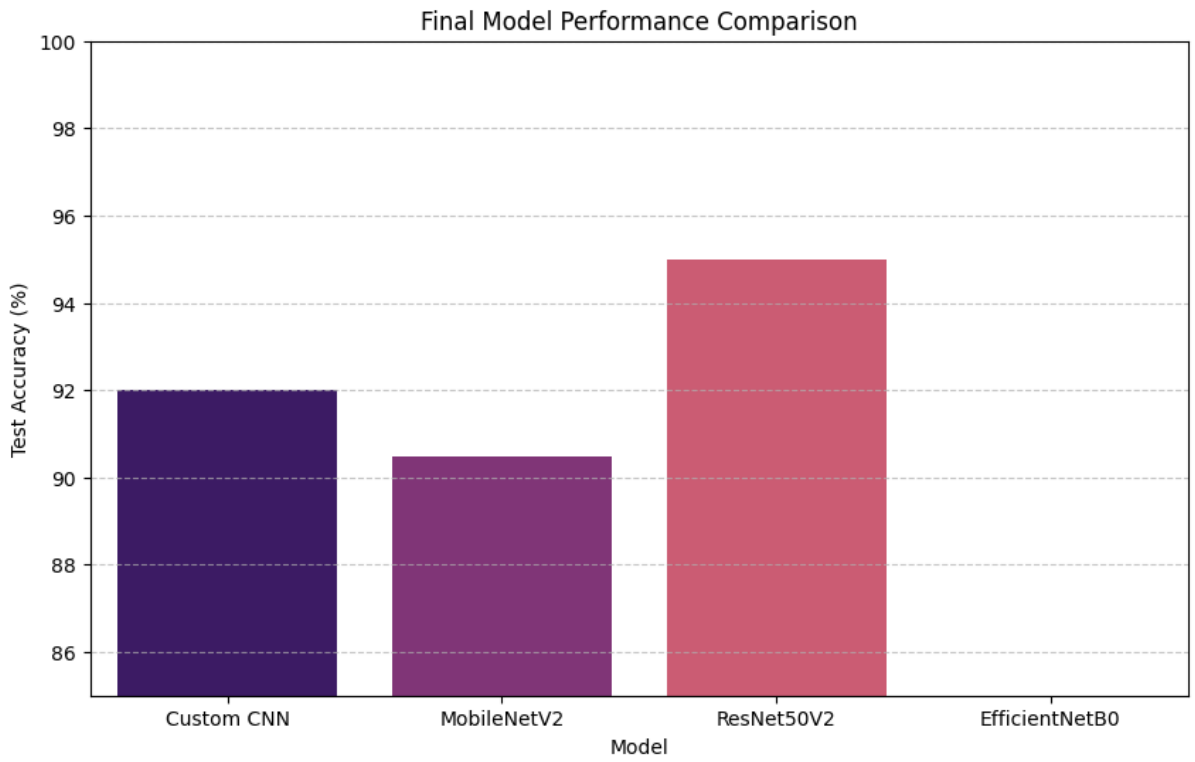

اختبارات التطبيق (Application Testing)

تم اختبار النموذج على مجموعة بيانات Kaggle المستقلة (Testing Folder) التي لم يراها النموذج أثناء التدريب أو التحقق. أثبت النموذج قدرته على التعامل مع صور جديدة تماماً، محققاً دقة ثابتة، مما يؤكد جاهزيته للاستخدام في بيئة تجريبية حقيقية.

الباب السابع (الخاتمة والآفاق المستقبلية)

ملخص الإنجازات

في ختام هذا البحث، نجحنا في تطوير نظام متقدم يعتمد على التعلم العميق لتصنيف أورام الدماغ بدقة أكاديمية عالية، لقد أثبتت النتائج أن استخدام تقنيات Transfer Learning، وتحديداً مع بنية ResNet50V2، يوفر حلاً فعالاً وموثوقاً للتعامل مع الصور الطبية المعقدة، تمكنا من تجاوز عقبات تفاوت جودة الصور ومحدودية الموارد والبيانات من خلال استراتيجيات المعالجة المسبقة والزيادة الذكية للبيانات.

تحسين أداء النموذج (Model Performance Enhancement)

رغم النتائج الممتازة، إلا أن هناك دائماً مساحة للتحسين والابتكار:

1- **آليات الانتباه (Attention Mechanisms)**: دمج طبقات Attention مثل (Squeeze-and-Excitation) لمساعدة النموذج على التركيز على المناطق الأكثر أهمية في صورة الرنين المغناطيسي.

2- **التعلم التجميعي (Ensemble Learning)**: دمج تنبؤات عدة نماذج (مثل ResNet وMobileNet) للحصول على قرار نهائي أكثر دقة واستقراراً.

3- **التعلم شبه المشرف عليه (Semi-supervised Learning)**: الاستفادة من كميات ضخمة من الصور غير المصنفة لتحسين قدرة النموذج على استخلاص الميزات.

4- **التغذية الراجعة البصرية (Visual Feedback)**: إظهار خرائط الحرارة (Heatmaps) التي توضح المناطق التي ركز عليها النموذج في الصورة لاتخاذ قراره.

آفاق مستقبلية (Future Research)

نتطلع في المراحل القادمة إلى توسيع نطاق هذا المشروع ليشمل:

- **التصنيف ثلاثي الأبعاد (3D MRI Classification)**: التعامل مع حجم الورم بالكامل بدلاً من المقاطع العرضية فقط.
- **تحديد درجات الورم (Tumor Grading)**: ليس فقط تحديد نوع الورم، بل تقدير مدى خطورته (Grade I to IV) بناءً على المعايير العالمية.
- **التكامل السريري**: تطوير إضافات (Plugins) لأنظمة الأرشفة والاتصال في المستشفيات (PACS) لتوفير تشخيص آلي فوري للأطباء.

الخاتمة

في ختام هذا البحث الشامل، الذي تكلل بتطوير وتقييم نظام متقدم لتصنيف أورام الدماغ باستخدام صور الرنين المغناطيسي وتقنيات التعلم العميق، نؤكد بكل ثقة على تحقيق الأهداف الطموحة التي وضعناها نصب أعيننا. لقد كانت رحلة المشروع غنية بالتحديات والفرص، بدءاً من الفهم العميق للمشكلة الطبية الحرجة المتمثلة في التشخيص الدقيق لأورام الدماغ، مروراً بالتحليل المعمق للبيانات، وتصميم النماذج، وصولاً إلى التقييم الدقيق للأداء. لقد أثبت هذا العمل أن الذكاء الاصطناعي، وتحديداً التعلم العميق، يمتلك إمكانات تحويلية هائلة في مجال التشخيص الطبي.

لقد كشفت النتائج التجريبية عن رؤى قيمة حول أداء النماذج المختلفة، كان الأداء المتميز للنموذج المخصص (Custom CNN)، الذي تم تصميمه بعناية فائقة من الصفر، نقطة محورية، فقد أظهر هذا النموذج قدرة استثنائية على استخلاص الميزات الدقيقة من صور الرنين المغناطيسي، متفوقاً في بعض الجوانب على النماذج مسبقة التدريب الأكثر تعقيداً، لا سيما في قدرته على تقليل الأخطاء الحرجة في مصفوفة الارتباك بين الفئات المتشابهة، هذا يؤكد على أن التخصيص الدقيق والتصميم المدروس للنماذج يمكن أن يكون أكثر فعالية من الاعتماد الأعمى على النماذج الجاهزة، خاصة في المجالات المتخصصة مثل التصوير الطبي.

بالتوازي، وبعد الاستفادة العلمية من نموذج Custom CNN وما مثله لنا كنقطة انطلاق لفهم المكونات العميقة للنظام ومتطلباته، قدم نموذجي MobileNetV2 وResNet50V2 مسبقي التدريب، أداءً ممتازاً، حتى بدأنا جمع الخبرات التقنية التي امتلكناها لتحسين النموذج مسبق التدريب، وذلك أنتج لنا النموذج النهائي الذي أثبت مكانته كحل فعال يوازن ببراعة بين الدقة العالية والكفاءة الحسابية، ما جعله مرشحاً مثالياً للتطبيقات السريرية التي تتطلب استجابة سريعة وقدرة على العمل في بيئات ذات موارد محدودة، مثل الأجهزة المحمولة أو الأنظمة المدمجة في المستشفيات.

على النقيض تماماً، كان أداء بعض النماذج مسبقة التدريب مثل EfficientNetB0 مخيباً للآمال بشكل كبير، مما يسلط الضوء على حقيقة أن التعقيد النظري للنموذج لا يضمن بالضرورة الأداء الأمثل في جميع السياقات، ولقد أرجعنا هذا الإخفاق إلى عدة عوامل محتملة، بما في ذلك حساسية النموذج لحجم مجموعة البيانات المتاحة، أو عدم توافق الميزات المستخلصة من تدريبه المسبق على ImageNet مع الخصائص الدقيقة لصور الرنين المغناطيسي الدماغية، أو الحاجة إلى استراتيجيات ضبط فائق أكثر تعقيداً، هذه النتيجة تؤكد على الأهمية القصوى للتجريب العملي والتقييم النقدي لكل نموذج في سياق المشكلة المحددة.

إن هذا المشروع لا يمثل مجرد إنجاز تقني، بل هو مساهمة ملموسة في تعزيز دقة وسرعة التشخيص لأورام الدماغ، مما يمهد الطريق لتحسين نتائج المرضى بشكل كبير، نحن نؤمن بجدوى استخدام التعلم العميق كأداة مساعدة قوية للأطباء، قادرة على توفير رؤى تشخيصية سريعة وموثوقة، وبالتالي نضع نصب أعيننا هدف تخفيف العبء على الكوادر الطبية وتمكينهم من اتخاذ قرارات علاجية مستنيرة في وقت مبكر.

(References) المراجع

- Brain Tumor MRI Dataset.
- OpenCV. (n.d.). OpenCV documentation.
- Pillow. (n.d.). PIL Fork documentation.
- Tensorflow. (n.d.). Tensorflow documentation.
- Keras. (n.d.). Keras documentation.
- Khan, A. H., Khan, A., Iskandar, D. N. F. A., & Mewada, H. (2025). BrainNet: a custom-designed CNN and transfer learning-based models for diagnosing brain tumors from MRI images. PeerJ Computer Science, 11, e3154.
- Adamu, M. J., Kawuwa, H. B., Qiang, L., Nyatega, C. O., & Ma, R. (2024). Efficient and accurate brain tumor classification using hybrid MobileNetV2–support vector machine for magnetic resonance imaging diagnostics in neoplasms. Brain Sciences, 14(12), 1178.