العربية:

تُعد أورام الدماغ تحدياً صحياً عالمياً يهدد حياة الملايين، حيث يتطلب تشخيصها المبكر والدقيق خبرة عالية ووقتًا طويلاً، مما يؤثر بشكل مباشر على فعالية العلاج ونتائج المرضى. في ظل التزايد المستمر لحجم البيانات الطبية وتعقيدها، يبرز الدور المحوري لتقنيات الذكاء الاصطناعي، وتحديداً التعلم العميق، كأدوات واعدة لتحسين كفاءة ودقة التشخيص. يهدف هذا المشروع البحثي إلى تطوير نظام آلي متقدم لتصنيف أورام الدماغ من صور الرنين المغناطيسي (MRI)، وذلك لتقديم دعم تشخيصي موضوعي وسريع للكوادر الطبية، وتقليل الاعتماد على التفسير البشري الذي قد يكون عرضة للاختلافات.

تضمنت المنهجية المتبعة في هذا المشروع عدة مراحل رئيسية. بدأت المرحلة الأولى بجمع ومعالجة مجموعة بيانات شاملة لصور الرنين المغناطيسي الدماغية، والتي تم تصنيفها إلى أربع فئات: Glioma، Meningioma، Pituitary، و No Tumor. تم تطبيق تقنيات معالجة مسبقة للصور لتوحيد الأبعاد وتحسين الجودة، بالإضافة إلى استخدام تقنيات زيادة البيانات (Data Augmentation) لتعزيز حجم وتنوع مجموعة التدريب، مما يساهم في تحسين قدرة النماذج على التعميم. في المرحلة الثانية، تم تصميم وتطبيق مجموعة متنوعة من نماذج الشبكات العصبية التلافيفية (CNNs). شملت هذه النماذج: نموذجاً مخصصاً (Custom CNN) تم بناؤه من الصفر ليتناسب مع خصائص صور الرنين المغناطيسي، ونماذج سابقة التدريب (Pre-trained Models) مثل MobileNetV2 وResNet50V2، والتي تم ضبطها بدقة (Fine-tuned) على مجموعة بياناتنا للاستفادة من الميزات المستخلصة من مجموعات بيانات كبيرة مثل ImageNet. تم تدريب هذه النماذج وتقييمها باستخدام مقاييس أداء صارمة مثل الدقة (Accuracy)، والشمول (Recall)، والدقة (Precision)، ومقياس F1-score، بالإضافة إلى تحليل مصفوفات الارتباك (Confusion Matrices) ومنحنيات ROC.

كشفت النتائج التجريبية عن رؤى مهمة حول أداء النماذج المختلفة. أظهر النموذج المخصص (Custom CNN) أداءً ممتازاً ومفاجئاً، حيث حقق دقة عالية وتفوق في بعض جوانب التمييز الدقيق بين فئات الأورام المختلفة، لا سيما في تقليل الأخطاء الحرجة بين الفئات المتشابهة، مما يشير إلى فعالية تصميمه الموجه للبيانات الطبية. كما قدم ResNet50V2 أداءً قوياً وفعالاً، مؤكداً على قدرته على تحقيق توازن مثالي بين الدقة العالية والكفاءة الحسابية، مما يجعله خياراً مثالياً للتطبيقات التي تتطلب سرعة في الاستدلال. على النقيض تماماً، واجه نموذج كـ EfficientNetB0 صعوبات كبيرة في التعلم والتعميم على مجموعة بياناتنا، حيث أظهر أداءً ضعيفاً بشكل ملحوظ. وقد عُزي هذا الإخفاق إلى عوامل محتملة مثل حساسية النموذج لحجم البيانات المتاحة، أو عدم توافق الميزات المستخلصة من تدريبه المسبق مع الخصائص الدقيقة لصور الرنين المغناطيسي الدماغية، أو الحاجة إلى استراتيجيات ضبط فائق أكثر تعقيداً.

في الختام، يؤكد هذا المشروع على الإمكانات الهائلة للتعلم العميق في تحسين دقة وسرعة تشخيص أورام الدماغ. لقد أثبتنا أن التصميم الدقيق للنماذج والتحليل المعمق للبيانات أمران حاسمان لتحقيق أفضل أداء في التشخيص الطبي. يساهم هذا النظام في تقديم أداة مساعدة قوية للأطباء، تدعمهم في اتخاذ قرارات علاجية مستنيرة، وتفتح آفاقاً واعدة لمزيد من البحث والتطوير في مجال الذكاء الاصطناعي الطبي، بهدف تحسين جودة حياة المرضى في جميع أنحاء العالم.

English:

Brain tumors represent a global health challenge that profoundly impacts human lives, demanding high expertise and significant time for early and accurate diagnosis. This directly affects treatment efficacy and patient outcomes. Amidst the continuous growth and complexity of medical data, artificial intelligence technologies, particularly deep learning, emerge as promising tools to enhance diagnostic efficiency and precision. This research project aims to develop an advanced automated system for classifying brain tumors from Magnetic Resonance Imaging (MRI) scans. The goal is to provide objective and rapid diagnostic support for medical professionals, reducing reliance on human interpretation, which can be prone to inter-observer variability.

The methodology adopted in this project encompassed several key stages. The initial phase involved collecting and processing a comprehensive dataset of brain MRI images, categorized into four classes: Glioma, Meningioma, Pituitary, and No Tumor. Image preprocessing techniques were applied to standardize dimensions and enhance quality. Furthermore, data augmentation techniques were utilized to expand the size and diversity of the training set, thereby improving the models' generalization capabilities. In the second phase, a variety of Convolutional Neural Network (CNN) models were designed and implemented. These included a Custom CNN built from scratch to suit the specific characteristics of MRI images, and pre-trained models such as MobileNetV2 and ResNet50B0, which were meticulously fine-tuned on our dataset to leverage features learned from large datasets like ImageNet. These models were trained and evaluated using rigorous performance metrics, including Accuracy, Recall, Precision, and F1-score, alongside the analysis of Confusion Matrices and ROC curves.

Experimental results revealed critical insights into the performance of the different models. The Custom CNN demonstrated excellent and surprising performance, achieving high accuracy and excelling in certain aspects of fine-grained discrimination between various tumor types, particularly in reducing critical errors in the confusion matrix between similar classes. This indicates the effectiveness of its medical-data-oriented design. ResNet50V2 also delivered strong and efficient results, confirming its capability to achieve an optimal balance between high accuracy and computational efficiency, making it an ideal choice for applications requiring rapid inference. In stark contrast, EfficientNetB0 encountered significant difficulties in learning and generalizing on our dataset, exhibiting notably poor performance. This failure was attributed to potential factors such as the model's sensitivity to the available dataset size, the incompatibility of features extracted from its pre-training with the specific characteristics of brain MRI images, or the need for more complex hyperparameter tuning strategies.

In conclusion, this project underscores the immense potential of deep learning in enhancing the accuracy and speed of brain tumor diagnosis. We have demonstrated that meticulous model design and in-depth data analysis are crucial for achieving optimal performance in medical diagnosis. This system contributes to providing a powerful assistive tool for clinicians, supporting them in making informed treatment decisions, and opening promising avenues for further research and development in medical artificial intelligence, with the ultimate goal of improving the quality of life for patients worldwide.